AVALIAÇÃO DE DESEMPENHO DO APACHE DRUID: ESTRUTURAÇÃO DE EXPERIMENTOS E ANÁLISE COMPARATIVA

Gabriel Gonçalves Sampaio[1] (IC), Barbara Pimenta Caetano[1] (PQ)

[1]*Instituto de Engenharia de Sistemas e Tecnologia da Informação (IESTI) - Universidade Federal de Itajubá (UNIFEI)*

E-mails: gabriel@unifei.edu.br, barbara.caetano@unifei.edu.br

RESUMO

O monitoramento geoespacial de desastres ambientais, especialmente o cruzamento em larga escala de incêndios florestais com infraestruturas críticas, exige arquiteturas de dados de baixa latência. Modelos tradicionais em lote (*batch*) enfrentam gargalos severos ao correlacionar milhões de anomalias térmicas com fronteiras demográficas e elétricas do Brasil de forma interativa. Para avaliar uma alternativa escalável, este trabalho foca na estruturação de experimentos e na análise comparativa de desempenho do banco de dados analítico colunar Apache Druid, inserido em um fluxo *DataOps* de processamento em tempo real. A metodologia envolveu a ingestão de 3,3 milhões de focos de calor históricos e sua correlação cruzada, na memória via *Lookups*, com entidades como municípios, hospitais, malhas de transmissão elétrica e terras indígenas. A avaliação operacional baseou-se em testes de estresse progressivo (*Query Per Second* - QPS) e no escalonamento horizontal de vCPUs e da segmentação do banco. Os resultados demonstram que estratégias compactas de alocação garantiram ganhos de vazão de até 38,8 vezes em relação a estratégias fragmentadas sob o mesmo hardware de 6 vCPUs. Adicionalmente, as avaliações de latência *Percentil 95* (P95) indicaram que o sistema é capaz de resolver filtragens espaciais intensas em tempos que variam entre 2,8 a 8,2 segundos nos piores cenários de concorrência, suportando a carga sem estourar limites rígidos de RAM ($\sim$850 MB por nó na camada de cache). Conclui-se que o Apache Druid atende aos requisitos operacionais para inteligência geoespacial rápida, desde que a razão entre a taxa de requisições e a paralelização dos segmentos dos dados seja cuidadosamente calibrada.

Palavras-chave: Apache Druid. Benchmarking. DataOps. Processamento Analítico (OLAP). Monitoramento Geoespacial.

Área de Conhecimento: Ciência da Computação
Campus: Itajubá

1 INTRODUÇÃO

As mudanças climáticas têm refletido na incidência de desastres ambientais no Brasil. Apenas no primeiro semestre de 2026, registraram-se 19.462 focos de incêndio [18], complementando os registros de 2024, quando o fogo consumiu 30 milhões de hectares no país, predominantemente sobre florestas nativas na Amazônia [14]. A detecção isolada de anomalias térmicas satelitais, contudo, necessita ser correlacionada de forma contínua às vulnerabilidades demográficas e infraestruturais para subsidiar mitigações eficazes.

A integração de bases institucionais (INPE [12], FUNAI [8], ANEEL [1], IBGE [11], DATASUS [13]) aos dados de satélite enfrenta profundos desafios de latência e padronização geométrica. Plataformas consolidadas, como o Painel do Fogo [3], prestam suporte essencial, porém arquiteturas de processamento baseadas em lotes (*batch*) apresentam gargalos de vazão ao cruzar milhões de registros geoespaciais e séries temporais de forma interativa. Agregar massas de dados dinâmicas para a geração de respostas analíticas instantâneas permanece um limite técnico em sistemas tradicionais.

Diante dessa barreira, bancos de dados analíticos colunares (OLAP) orientados a *streaming*, como o Apache Druid, despontam como soluções ideais para a absorção paralela de *logs* em tempo real. Contudo, apesar de sua eficiência arquitetural no isolamento entre armazenamento e consulta [19], ainda é incerto o impacto na latência quando tais motores são submetidos a volumétricas e complexas junções espaciais interativas (*Lookups*) operando sob restrições severas de hardware e limitação de RAM.

Este trabalho tem como objetivo principal avaliar o desempenho e a estabilidade de processamento do Apache Druid frente a um rigoroso modelo de estresse analítico de dados geoespaciais e ambientais. Para ancorar o experimento em uma realidade aplicada, utiliza-se o SIRDA (Sistema de Inteligência e Resposta a Desastres Ambientais) como estudo de caso, implementando um fluxo *DataOps* contínuo [7] capaz de consolidar riscos topológicos para a Defesa Civil.

O *benchmark* estruturado revela que a otimização na compactação dos dados em segmentos possui um impacto superior ao aumento bruto de poder de processamento, registrando um ganho de 38,8 vezes na vazão de resposta frente a estratégias fragmentadas sob o mesmo hardware. Adicionalmente, os resultados destacam o fenômeno computacional *Too Fast to Cache*, demonstrando que o sistema é capaz de resolver filtragens relacionais em tempos sub-segundo tão rapidamente que a contenção imposta à memória RAM pelo motor interno torna-se um limite arquitetural intransponível antes mesmo que as CPUs atinjam a saturação plena.

2 REFERENCIAL TEÓRICO

Diante do gargalo tecnológico provocado pela fragmentação de bases de dados geográficas e ambientais, as agências de controle carecem de ferramentas capazes de prover uma visão unificada e contínua do risco sistêmico, um estado mental de percepção, compreensão e projeção frequentemente denominado pela literatura como Consciência Situacional [6]. Desta forma, a principal vocação do SIRDA é fornecer inteligência acionável para órgãos de controle ambiental e de infraestrutura, tendo essa meta teoricamente embasada pelo modelo seminal de Mica R. Endsley.

Em seu trabalho *"Toward a theory of situation awareness in dynamic systems"*, Endsley estipula que a Consciência Situacional não se resume à simples coleta de dados, mas divide-se obrigatoriamente em três grandes níveis cognitivos e sistêmicos: Percepção (Nível 1), Compreensão (Nível 2) e Projeção (Nível 3). Na arquitetura do SIRDA, a ingestão de anomalias térmicas via satélite (Nível 1) é cruzada geoespacialmente com infraestruturas críticas para determinar o contexto de risco (Nível 2), culminando em simulações topológicas que projetam o impacto iminente de incêndios sobre as redes de transmissão (Nível 3). É essa taxonomia que justifica plenamente o emprego de tecnologias de processamento de fluxos em tempo real (*Streaming*) e de painéis interativos de resposta rápida que alimentam a camada analítica do projeto.

Para materializar essa estrutura complexa de Consciência Situacional sem ceder ao caos operacional de arquiteturas legadas, o SIRDA fundamenta-se nos princípios do DataOps. Diferentemente de abordagens tradicionais de rotinas ETL (Extração, Transformação e Carga), a plataforma assimila o DataOps conforme conceituado por Julian Ereth [7]. Em seu artigo *"DataOps: towards a definition"*, Ereth formaliza que esse paradigma transcende a mera automação, caracterizando-se pela incorporação sistemática das práticas estruturadas da Engenharia de Software ao ciclo de vida da Engenharia de Dados.

Para a gestão de catástrofes ambientais, essa abordagem teórica mostra-se indispensável. Quando o tempo de resposta é crítico, não há margem para erros estruturais nas tabelas ou quedas silenciosas de integração. A teoria de Ereth aplica-se ao nosso caso de uso por meio da imposição de tipagens estritas nos contratos de dados e na orquestração de alto nível dos processos. Isso evita que falhas em fontes primárias propaguem dados sujos ou geometrias inválidas para o banco de dados analítico final. A utilização de sistemas OLAP para a tomada de decisão é amplamente embasada na literatura [4], sendo que a plataforma propõe a adoção deste conceito para o processamento de eventos escaláveis com o Apache Druid [19]. Tais práticas garantem que os gestores de crise tomem decisões pautadas em informações íntegras e validadas.

3 ARQUITETURA E ESPECIFICAÇÕES TÉCNICAS

A concepção do SIRDA (Sistema de Inteligência e Resposta a Desastres Ambientais) afasta-se do uso exclusivo de bancos de dados relacionais clássicos, adotando um ecossistema distribuído de *Big Data* construído inteiramente sobre ferramentas de código aberto (*open-source*). Esta escolha técnica provê escalabilidade ao acesso analítico e garante a capacidade de processar volumes massivos de anomalias térmicas, cruzando essas informações com geometrias complexas de infraestrutura em uma janela de tempo crítica. A arquitetura foi estruturada em torno das seguintes tecnologias:

- **Apache Kafka:** Atua como o sistema nervoso central de mensageria, absorvendo picos severos de dados durante períodos críticos de queimadas, promovendo o desacoplamento entre a extração dos dados e a ingestão no banco analítico.
- **Apache Druid:** O motor OLAP (*Online Analytical Processing*) escolhido pela sua capacidade nativa de ingerir fluxos de dados diretamente do Kafka (*Streaming Ingestion*) e fornecer respostas analíticas em escala de baixa latência (poucos segundos).
- **PostgreSQL:** Empregado como o banco relacional de suporte, atuando estritamente como *Metadata Store* para o Druid e para o sistema de visualização gráfica.
- **Dagster:** Orquestrador central que rege o paradigma DataOps do projeto. Ele garante a execução limpa, tipada e rastreável dos processos de enriquecimento espacial e publicação de mensagens no Kafka.
- **Apache Superset:** Camada visual que materializa o Nível 3 da Consciência Situacional, entregando painéis gerenciais e topológicos aos tomadores de decisão.

Para assegurar a reprodutibilidade e a portabilidade do sistema, a infraestrutura foi inteiramente conteinerizada via Docker. A topologia orquestrada no *docker-compose* reflete fielmente um ambiente de produção resiliente. Destaca-se que o banco de dados analítico Apache Druid não foi instanciado como um serviço monolítico, mas sim desmembrado em seus microsserviços fundamentais: *Coordinator*, *Broker*, *Historical*, *MiddleManager* e *Router*. Essa granularidade permite que a gestão de metadados, o roteamento de consultas e o processamento de dados ocorram em instâncias independentes, mitigando gargalos e falhas em cascata.

Além da separação lógica, a implantação local adota restrições físicas de hardware para mimetizar limitações produtivas reais. Foram aplicados limites explícitos de uso de processamento e memória RAM para cada serviço (*deploy resources limits*) na configuração dos contêineres. Paralelamente, os parâmetros da Máquina Virtual Java (JVM) de cada componente do Druid foram estritamente ajustados, por meio das variáveis

JAVA_OPTS, definindo precisamente os tamanhos do *heap* (*-Xms* e *-Xmx*) e da memória direta (*MaxDirectMemorySize*). Esses controles evitam o esgotamento prematuro de recursos da máquina hospedeira (*Out of Memory*), assegurando a estabilidade ininterrupta do *pipeline* de resposta a desastres, conforme sumarizado na Tabela 1.

Tabela 1: Alocação de Recursos e Parâmetros JVM (Docker).

Serviço	**vCPUs**	**RAM Total**	**JVM Heap** (*Min/Max*)	**JVM Direct Mem.**
Zookeeper	0.25	256M	128M / 128M	-
Apache Kafka	0.75	512M	256M / 256M	-
PostgreSQL	0.50	256M	-	-
Druid Coordinator	0.50	384M	128M / 256M	-
Druid Broker	1.0	768M	256M / 512M	512M
Druid Historical	1.0	768M	256M / 512M	512M
Druid MiddleManager	1.0	1024M	128M / 128M*	128M*
Druid Router	0.25	384M	128M / 128M	-
Apache Superset	1.0	768M	-	-
Dagster	0.75	256M	-	-

* O *MiddleManager* também aloca instâncias filhas (*Peon Workers*) com Heap de 512M / 512M.

Fonte: Elaborada pelos autores.

Os valores estipulados na Tabela 1 representam a configuração **Baseline** estática da arquitetura. Conforme detalhado nos resultados, durante a bateria de estresse de vazão analítica, essas cotas de processamento para os nós *Broker* e *Historical* foram sistematicamente escalonadas até 2.0 vCPUs para mapear os ganhos de eficiência do sistema sob pressão.

A assimetria observada reflete diretamente o perfil analítico de cada nó. O *MiddleManager* aloca a maior cota absoluta de RAM por orquestrar o *streaming* volátil e o agrupamento inicial de dados antes da indexação em disco. Em contrapartida, instâncias focadas em pesquisa complexa (*Broker* e *Historical*) maximizam a alocação de vCPU e Memória Direta, preservando o *Heap* padrão da JVM para evitar pausas prolongadas de *Garbage Collection* durante os cruzamentos espaciais. Os nós de gestão (*Coordinator* e *Router*) operam com capacidade reduzida, pois não realizam operações matemáticas diretas.

3.1 Modelagem Analítica: Esquema Constelação

Para suprir os requisitos analíticos de baixa latência do Apache Druid, a modelagem de dados afasta-se da normalização tradicional e adota um *Esquema Constelação* altamente desnormalizado. Neste modelo, as anomalias térmicas brutas e os agrupamen-

tos de desastres formam as duas Tabelas Fato centrais, cercadas por Dimensões de busca contendo as chaves geográficas e infraestruturais pré-computadas, otimizando as agregações interativas na interface visual (Figura 1).

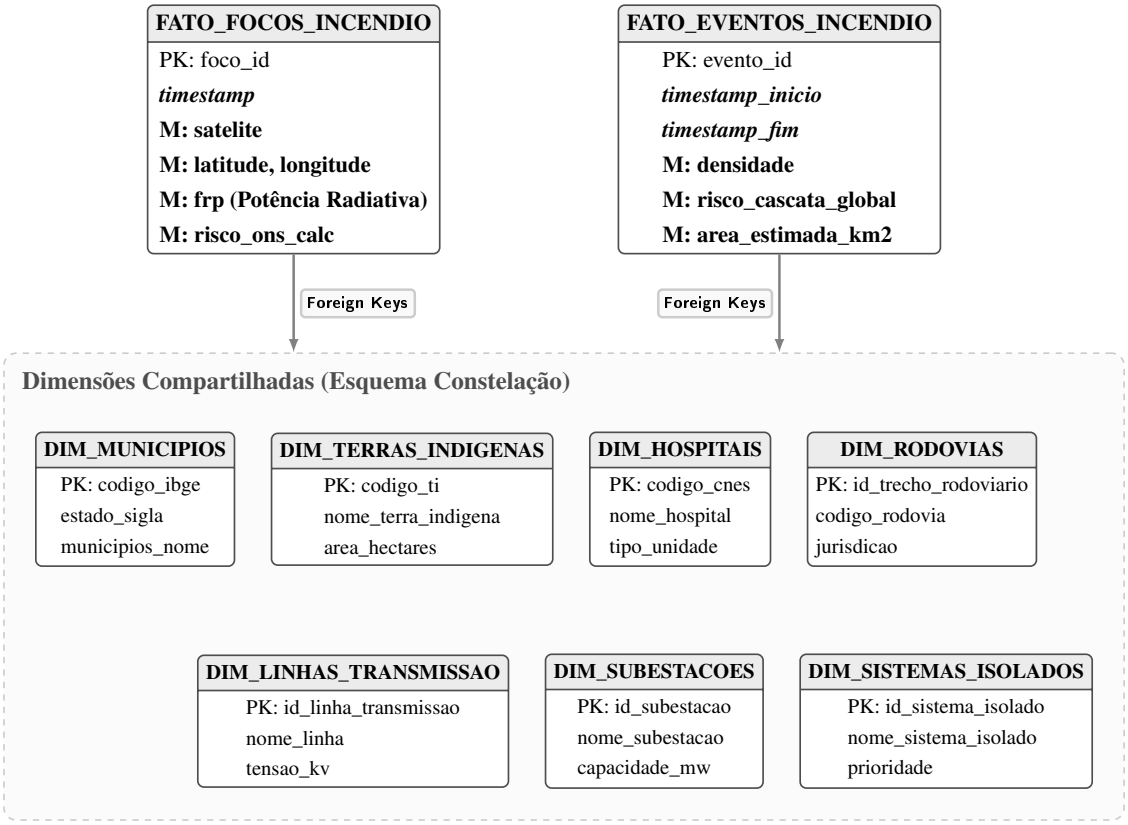


Figura 1: Modelo Entidade-Relacionamento (Constelação).

Fonte: Elaborada pelos autores.

3.2 Orquestração Orientada a Dados (Dagster)

Para orquestrar o cruzamento das malhas elétricas e inferências de ciência de redes, o projeto adota uma abordagem estritamente focada em dados por meio da abstração de *Software-Defined Assets* (SDA) do Apache Dagster. Diferentemente de orquestradores tradicionais focados em fluxos de tarefas genéricas, o modelo implementado estabelece um grafo declarativo de linhagem explícita (*Lineage*).

Como ilustrado na Figura 2, a arquitetura não utiliza agendamentos temporais órfãos. A extração da infraestrutura linear (`aneel_ons_data`) figura como a raiz do grupo `infra_ons`. Essa malha base torna-se pré-requisito funcional absoluto (`deps=[...]`) para a segmentação subsequente das tabelas de Subestações e Linhas de Transmissão. Somente após a materialização bem-sucedida dessas dependências físicas é que o Dagster autoriza a execução dos algoritmos analíticos pesados do grupo `science_models`, como o cálculo topológico `network_centrality_model`.

Isso garante idempotência e tipagem granular: falhas em rotinas de extração bloqueiam instantaneamente a propagação de anomalias para os motores de agregação espacial (NetworkX e Scikit-Learn), blindando a modelagem arquitetural contra estados incompletos.

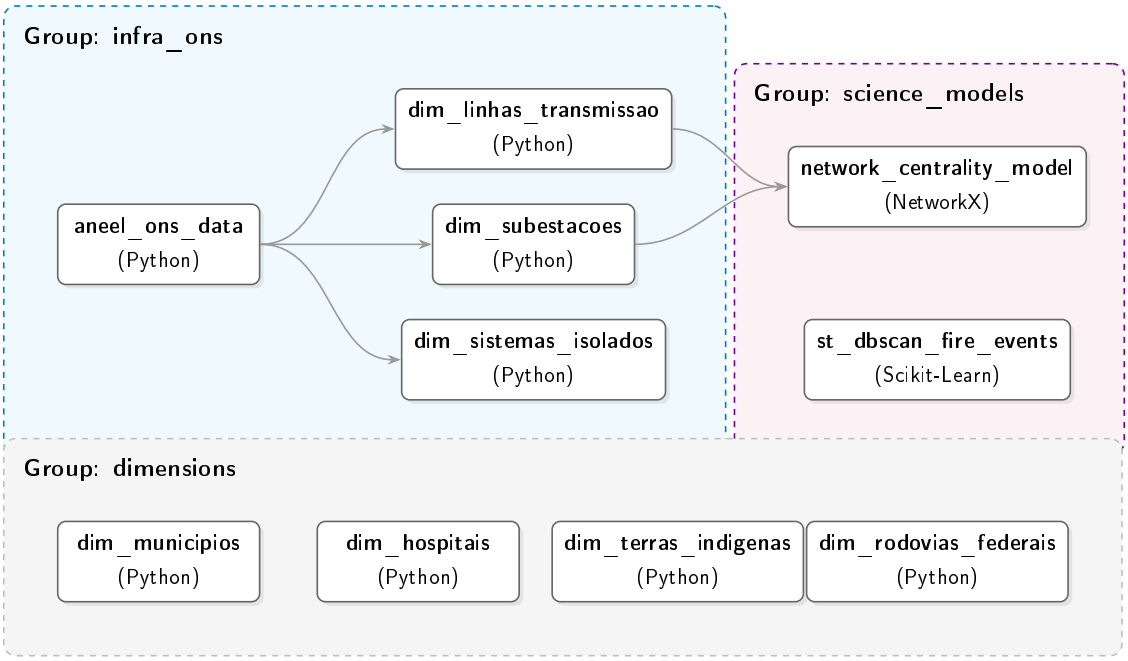


Figura 2: Grafo de Dependência Declarativa (Software-Defined Assets).

Fonte: Elaborada pelos autores.

3.3 Data Flow End-to-End (Streaming e OLAP)

A Figura 3 ilustra a primeira fase do fluxo contínuo de processamento da arquitetura *Medallion*. A extração inicia-se a partir das coordenadas brutas de satélites e das fontes dimensionais. Em vez de persistir o dado bruto inicialmente em disco, a principal premissa arquitetural adotada foi a paralelização em nível de mensageria através do Produtor Kafka, permitindo o enriquecimento em tempo real.

Esse fluxo contínuo (*Streaming Dual-Branch*) bifurca as informações imediatamente: o *Ramo dos Focos* analisa os registros pontuais de forma quase instantânea, enquanto o *Ramo dos Eventos* acumula janelas temporais para a agregação poligonal no *DBSCAN*. Ambas as esteiras invocam o *Motor Espacial* simultaneamente e empacotam seus resultados sob contratos rigidamente tipados (`FocoFatoPayload` e `EventoFatoPayload`).

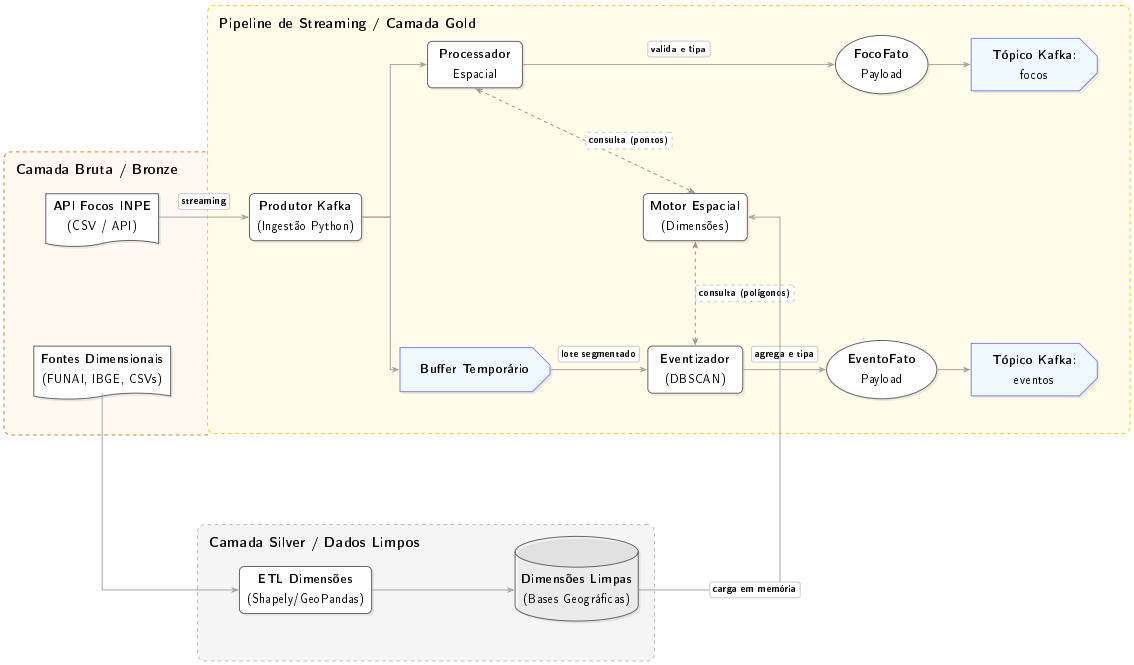


Figura 3: Fluxo de Ingestão e Processamento (Fase 1).

Fonte: Elaborada pelos autores.

Uma vez inseridos nos tópicos de saída, os dados roteados dão início à segunda fase operacional, cujo consumo analítico é detalhado na Figura 4. As mensagens em *streaming* são ingeridas de forma segmentada pelos nós do Apache Druid, consolidando as Tabelas Fato `fato_focos` e `fato_eventos`. Isso viabiliza pesquisas em frações de segundo e sustenta as renderizações da camada de apresentação, servida através de painéis interativos no Apache Superset.

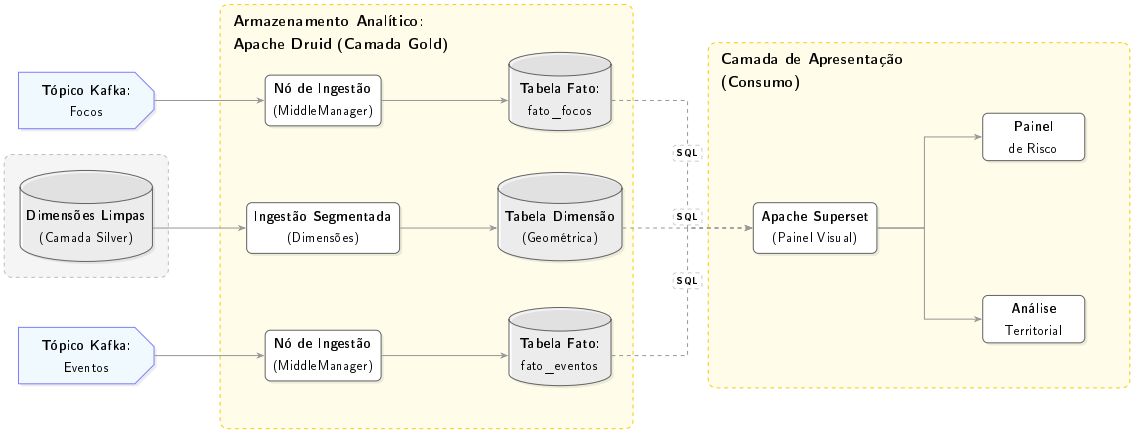


Figura 4: Fluxo de Armazenamento Analítico e Visualização (Fase 2).

Fonte: Elaborada pelos autores.

3.4 Estratégia de Processamento Espacial Híbrido (Python e Druid)

Embora o Apache Druid possua capacidades nativas de indexação e filtragem espacial, a execução de junções espaciais densas (*Point-in-Polygon joins*) entre milhões de anomalias térmicas e geometrias poligonais complexas, como os limites irregulares de Terras Indígenas ou municípios continentais, representa uma carga computacional intensa. Delegar essa operação de interseção ao motor OLAP durante a ingestão ou consulta degradaria significativamente a vazão (*throughput*) e a latência analítica.

Para mitigar esse gargalo, a arquitetura adota um processamento espacial híbrido, deslocando o enriquecimento geográfico para as camadas prévias de orquestração. O cruzamento é executado em memória através da biblioteca GeoPandas (Python), que tira proveito de estruturas de indexação em árvore (*R-Tree*). Esse método particiona o espaço topológico, reduzindo a complexidade temporal da busca espacial de $O(N)$ para $O(\log N)$. Como resultado, os pacotes (*payloads*) transmitidos via Kafka chegam ao Apache Druid em formato tabular desnormalizado e já enriquecidos com suas chaves infraestruturais, permitindo que o banco atue exclusivamente na agregação analítica de hipervelocidade.

4 METODOLOGIA EXPERIMENTAL, MATEMÁTICA E DE VISUALIZAÇÃO

Para prover embasamento científico e validar as propostas arquiteturais do sistema, idealizou-se uma metodologia sistemática dividida em três pilares analíticos: os testes de estresse em ambiente de simulação, a modelagem matemática das ameaças físicas e a visualização tática no nível operacional. Todo o arcabouço metodológico visa testar a escalabilidade e a resiliência do ecossistema frente à escassez de recursos físicos, garantindo a entrega ágil de informações.

4.1 Cenários de Hardware Restritivos

A estratégia de testes não se concentrou puramente na otimização algorítmica do código SQL ou na alteração do esquema de dados, mas sim na alocação de recursos físicos subjacentes (vCPU e Memória RAM) para os nós distribuídos do Apache Druid (*Broker* e *Historical*). O propósito foi descobrir o limite de capacidade analítica sustentada antes da ocorrência de falhas (*Timeouts* e *Out Of Memory*) ou da degradação inaceitável na latência. Todos os contêineres foram hospedados em uma mesma máquina física local, equipada com um processador Intel Core i5-1135G7 (8 *threads* lógicas), 8GB de RAM e sistema operacional Ubuntu 24.04 LTS.

Para tanto, foram estabelecidos três perfis distintos de capacidade isolados via conteinerização (*docker-compose*):

- **Cenário Baseline (1.0 vCPU e 1 GB RAM):** Motor restrito a recursos escassos, mimetizando servidores de entrada e baixo custo. Neste cenário, o motor conta ape-

nas com uma *Thread* de processamento e um *Merge Buffer*, forçando um agressivo enfileiramento de requisições concorrentes.

- **Cenário Balanced (1.5 vCPU e 1.5 GB RAM):** Acréscimo moderado na capacidade de computação, elevando as *Threads* lógicas para duas, representando o uso diário em uma infraestrutura em nuvem mediana.
- **Cenário Query Heavy (2.0 vCPU e 2.0 GB RAM):** Foco primário na vazão matemática e mitigação de filas, alocando três *Threads* e três *Merge Buffers*, configuração destinada a estabilizar cruzamentos espaciais massivos.

As instâncias do Apache Druid foram progressivamente redimensionadas contra limites constantes do hospedeiro. A carga escalonada (1 a 16 *threads* concorrentes) mesclou cenários com e sem aquecimento da JVM (*Cold* e *Warm Start*). Cada bateria de estresse contínuo durou ~7 minutos, replicada em 3 rodadas para garantia estatística.

4.2 Taxonomia do *Workload* SQL e Justificativa de Benchmark

Na literatura de Bancos de Dados Analíticos, a aferição de desempenho tipicamente recorre a padrões sintéticos universais, como o TPC-H ou o *Star Schema Benchmark* (SSB) [15]. No entanto, esses modelos focam no estresse de *Joins* multi-tabelas em esquemas normalizados, falhando em emular o vetor de degradação primário deste projeto: o tráfego maciço de dicionários espaciais (matrizes GeoJSON) alocados na memória *Heap* da JVM.

Portanto, rejeitaram-se as cargas sintéticas de prateleira em prol da engenharia reversa. Extraíram-se as 29 requisições SQL puras geradas nos bastidores pelo *Apache Superset* durante o uso real dos painéis. Tais consultas foram submetidas ao estresse repetitivo ininterrupto, dividindo-se nos seguintes eixos analíticos:

1. **Latência Simples:** Consultas restritas (como `COUNT(*)`) para isolar a barreira de tempo imposta pelo protocolo HTTP, servindo de controle para a rede.
2. **OLAP Pesado e Extensões Geográficas:** Avaliação da CPU via *Group By* e transporte de matrizes GeoJSON densas (*Payloads* de até milhares de vértices por polígono).
3. **Lookups em Memória:** O vetor central de estresse arquitetural. Com a semântica de *Joins* dimensionais executada via *Lookups* (mapas de *hash* em memória para evitar *shuffle* de rede), o teste força o *Broker* a instanciar na RAM matrizes espaciais volumosas contendo as entidades limitantes (TIs, Municípios e Hospitais), aplicando alta pressão nos *Merge Buffers*.

4. **Virtual Datasets Reais:** O isolamento definitivo. Extraiu-se nativamente a sintaxe SQL real produzida nos bastidores pelo *Apache Superset*, injetando as requisições puras diretamente na API REST do Druid.

4.3 Formulação Matemática de Intensidade e Severidade Ambiental

O sistema fundamenta suas análises em métricas termo-dinâmicas, estabelecendo o FRP (*Fire Radiative Power*) como a variável basilar do ecossistema. Fornecido diretamente pelos fluxos de dados abertos do INPE (Instituto Nacional de Pesquisas Espaciais) e medido em Megawatts (MW) pelos sensores orbitais (AQUA, TERRA, NOAA-20), o FRP quantifica instantaneamente a radiação térmica emitida pelo processo de combustão. Em nossa taxonomia computacional, um FRP ≥ 100 MW categoriza uma anomalia térmica *Extrema*, correlacionada com a potencial formação de pirocúmulos.

Para além da observação termal bruta, implementamos modelos meteorológicos para a avaliação do grau de perigo. Para isso, utilizamos como componente central a variável *Risco de Fogo do INPE* (`risco_inpe`), uma métrica probabilística (0 a 1) calculada diariamente pelo instituto que cruza umidade relativa do ar, temperatura e secura da vegetação. A partir dela, projetamos o **Índice de Condição Ambiental (ICA)** para avaliar o estágio crítico da atmosfera no momento da detecção:

$$\text{ICA} = \frac{risco_inpe \times \ln(dias_sem_chuva + 1)}{1 + precipitacao_{mm}} \tag{1}$$

A escolha do alisamento logarítmico ($\ln(x+1)$) é uma técnica matemática fundamental nesta modelagem: ela garante que o acréscimo de dias de estiagem agrave o índice, mas de forma suavizada, impedindo que períodos de seca extrema (ex: 120 dias sem chuva) distorçam as contas e ofusquem outras variáveis. O acréscimo de $+1$ previne o erro matemático de calcular $\ln(0)$. Este índice atua como um termômetro pré-fogo, sendo amortecido no denominador por eventos de precipitação detectados, assumindo estado "Crítico"sempre que supera 1.5, limiar este definido heuristicamente durante a calibração do sistema para isolar o decil superior de perigo ambiental.

Já a gravidade real de um incêndio em andamento é dada pelo **Índice de Queimada de Evento (IQE)**, o qual consolida a intensidade radiativa e o clima:

$$\text{IQE} = \frac{\ln(FRP + 1) \times (1 + risco_inpe) \times (1 + \ln(dias_sem_chuva + 1))}{1 + precipitacao_{mm}} \tag{2}$$

Novamente, o uso de $\ln(FRP+1)$ mitiga picos efêmeros extremos de radiação detectados pelos satélites (onde o FRP salta de dezenas para milhares de MW num único pixel), traduzindo o cenário em uma escala logarítmica normalizada. Eventos com IQE ≥ 20 denotam incêndios críticos sob secas severas e prolongadas (corte estipulado em-

piricamente para mitigar o ruído analítico de pequenos focos rurais). Estes índices de severidade, em âmbito operacional, servem de métrica basal de filtragem para categorizar os painéis do Apache Superset: anomalias de baixo risco climático são suprimidas visualmente nas interfaces de gestão (evitando poluição analítica do mapa), enquanto os eventos de categoria extrema dominam os algoritmos de ordenação e os rankings das defesas civis.

4.4 Agrupamento Espaço-Temporal (DBSCAN Reescalonado)

O processo de detecção de eventos críticos ocorre no Nível 2 de Consciência Situacional, onde focos de calor isolados são agrupados em clusters geográficos contínuos. Para tal, foi implementado o algoritmo DBSCAN clássico com o eixo temporal reescalonado, parametrizado com suporte da biblioteca *scikit-learn*. Em vez de utilizar o modelo ST-DBSCAN puro (que exige distâncias com limites duplos e independentes), o tempo foi normalizado e injetado diretamente como um terceiro eixo espacial virtual.

Para equalizar grandezas espaciais e temporais, o algoritmo converte distâncias temporais em distâncias métricas "virtuais"sob a regra:

$$t_{km} = t_{dias} \times \frac{eps_{km}}{\max(eps_{dias}, 0.001)} \tag{3}$$

O modelo operou com raio espacial (eps_{km}) de 5.0 km, tolerância temporal (eps_{dias}) de 2.0 dias e densidade mínima de 3 focos. Após projeção para o Sistema Policônico Nacional (EPSG:5880), os agrupamentos são delimitados via envoltória convexa (*Convex Hull*) no GeoPandas (Figura 5). O *cluster* resultante é classificado como *Megadesastre* caso aglutine mais de 5.000 focos ou 500 km² de área num recorte de sete dias.

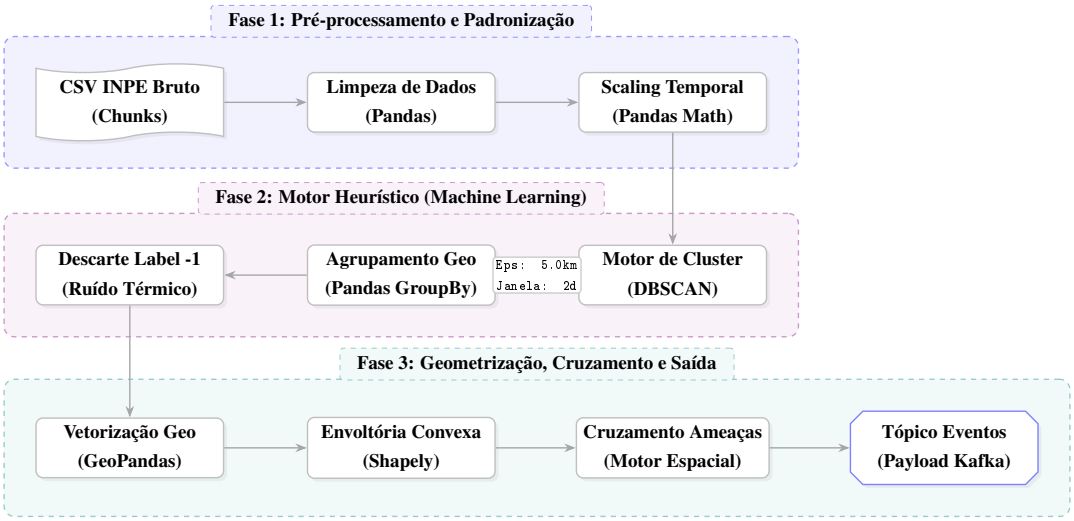


Figura 5: Arquitetura Espaço-Temporal do Eventizador (DBSCAN).

Fonte: Elaborada pelos autores.

4.5 Modelagem de Ameaças e Risco

4.5.1 Modelos Físicos de Pressão Humanitária e Territorial

Todo impacto civil medido pelo SIRDA fundamenta-se num decaimento métrico, onde a ameaça de um incêndio é inversamente proporcional à distância do ativo. A formulação matricial de cálculo adota o formato:

$$\text{Índice de Pressão} = \frac{FRP \times (1 + risco_inpe)}{\max(distancia_{km}, 0.1)} \tag{4}$$

Na **Pressão na Saúde**, o sistema cruza os polígonos de fogo com os ativos do CNES. Pontos com funcionamento "24h"e categoria "urgência/emergência"são isolados como Unidades Críticas, cujo colapso geraria sobrecarga sistêmica no SUS. Atingindo o índice de pressão 100 (limite heurístico de priorização visual), o cenário da instalação torna-se "Crítico".

O **Índice de Pressão Territorial** aplica a Equação 4 à base de Terras Indígenas (FUNAI). A ameaça territorial é subdividida via intersecções *shapely* como: DENTRO (distância euclidiana zero, configurando invasão de chamas) ou ENTORNO (distância maior que zero, mas sujeita aos efeitos radiais da fumaça).

4.5.2 Modelagem Topológica e Risco em Cascata (NetworkX)

No cume analítico (Nível 3), a segurança energética é avaliada em duas frentes complementares: o impacto termal direto e a topologia da rede. A vulnerabilidade térmica de uma instalação elétrica expande o Índice de Pressão civil (Equação 4), ponderando-o

pela magnitude estrutural do alvo. A formulação matemática da ameaça imediata sobre uma subestação isolada consolida-se por:

$$\text{Ameaça}_{\text{Subestação}} = \text{Índice de Pressão} \times \ln(capacidade_{MW} + 1) \tag{5}$$

Para além do impacto isolado, o sistema avança para simular a propagação do risco sistêmico modelando as Subestações e Linhas de Transmissão do ONS (Operador Nacional do Sistema Elétrico) como um grafo direcional via *NetworkX*. O pré-processamento espacial das geometrias EPSG:4326 recorre a um *Spatial Index* otimizado (*cKDTree*) para extrair uma matriz de adjacência georreferenciada baseada na proximidade dos terminais lógicos da malha elétrica, método reconhecido para a avaliação de vulnerabilidade em topologias elétricas.

A partir do grafo gerado, calcula-se a métrica de *Betweenness Centrality* (Centralidade de Intermediação), quantificando estruturalmente a suscetibilidade de uma subestação induzir blecautes caso seja atingida. Pontuações extremas são normalizadas entre 0-100, em que subestações avaliadas com escore ≥ 80 (ponto de corte empírico projetado para o topo da distribuição de vulnerabilidade) indicam nós críticos com risco de efeito cascata Severo/Extremo. Caso essas artérias centrais colapsem sob a ameaça física do fogo, a destruição causará interrupções macro-regionais ou bloqueios completos de escoamento elétrico (Figura 6).

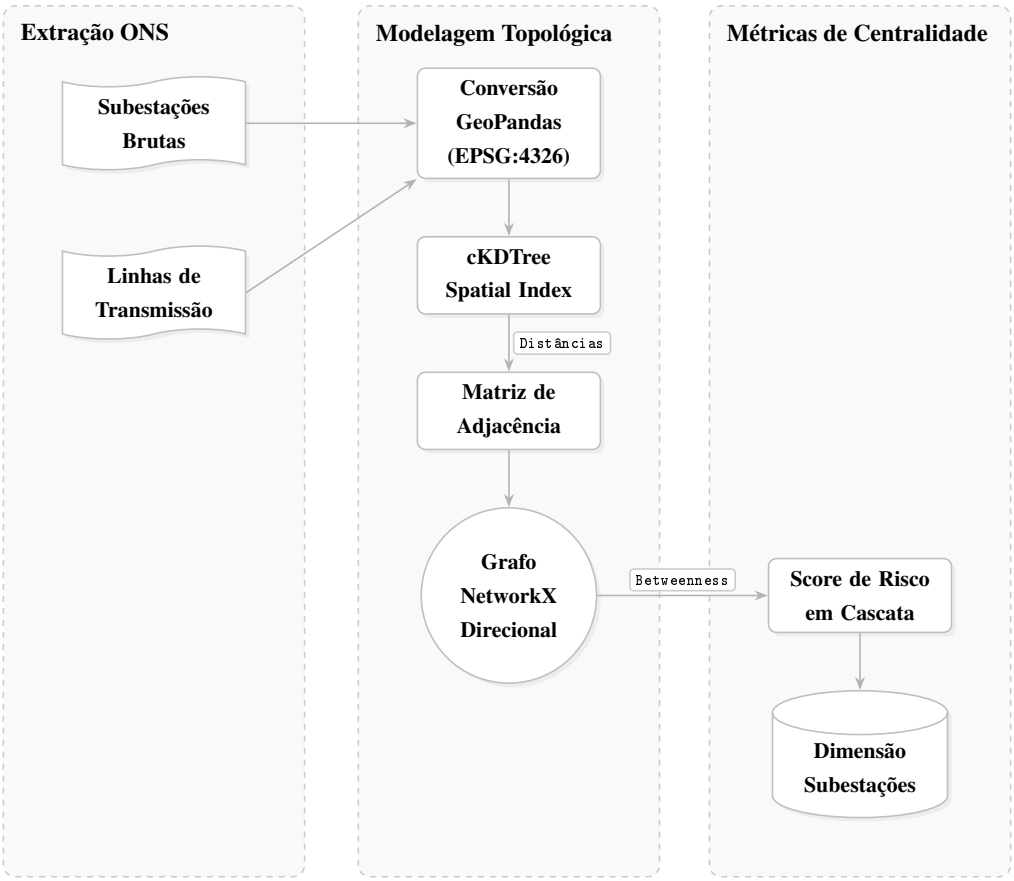


Figura 6: Cálculo de Centralidade de Risco via Grafos.

Fonte: Elaborada pelos autores.

4.6 Contextualização Operacional e Eficiência Visual

A materialização visual dos KPIs ocorreu no **Apache Superset**. Para mitigar estouros de memória no *Broker* ao renderizar matrizes GeoJSON no motor 3D (*Deck.gl*), injetou-se uma amostragem matemática no banco de dados. Como um limite simples (ex: `LIMIT 1000`) omitiria o país e aglomeraria os retornos num único estado, implementou-se uma função de *hash* determinístico espacial e temporal (`sample_bucket`) no Druid. A técnica garante que o mapa nacional espalhe estocasticamente os incidentes críticos pela tela, preservando a consciência situacional sem congestionar o navegador.

Adicionalmente, visando resolução assintótica $O(1)$, substituímos `JOINs` tradicionais por *Lookups* globais alocados na memória do Coordenador (cruzando rapidamente chaves de subestações e municípios). Os principais *Dashboards* resultantes cobrem:

- **Painel Geral (Níveis 1 e 2):** Apresenta mapeamento bruto da anomalia no país. Conta Área Queimada e evolução temporal.
- **Defesa Civil e Saúde (Nível 3):** Consolida a "Pressão Máxima"e alerta sobre leitos hospitalares pressionados por fuligem e linhas de fogo diretas.

- **Proteção Indígena (Nível 3):** Dedicado à sobreposição espacial dos eventos sobre polígonos legalmente restritos.
- **Segurança Energética (Nível 3):** Materializa a detecção de risco sistêmico via *NetworkX*. Identifica subestações de alta tensão na rota do desastre, embasando antecipações logísticas e re-despacho elétrico.

O desenvolvimento metodológico orientou-se para que as métricas processadas entregassem respostas na escala de poucos segundos, fundamentando assim a gestão de emergências críticas em tempo hábil.

4.7 Visualização Tática e Segmentação Operacional

A materialização matemática da Consciência Situacional é concretizada através da camada de apresentação no Apache Superset. Para mitigar a carga cognitiva de operadores em salas de situação, a construção dos *dashboards* seguiu o princípio da segmentação tática, dividindo o monitoramento em domínios operacionais distintos:

- **Visão Macro (Biomas e Sociedade):** Focada na análise exploratória geral, disponibilizando volumetria histórica, tendências temporais e mapas de calor consolidados em níveis estaduais e por biomas.
- **Vulnerabilidade Humanitária e Sanitária:** Interface direcionada à mitigação de crises diretas, evidenciando as métricas de pressão exercida pelo fogo sobre territórios sensíveis (Terras Indígenas) e sobre a rede de suporte crítico de saúde (Hospitais e Unidades de Pronto Atendimento).
- **Risco Estrutural em Redes Complexas:** Painel projetado para a equipe de infraestrutura, traduzindo visualmente os cálculos da Teoria dos Grafos. A interface destaca os nós da malha elétrica com base em sua Centralidade de Intermediação e estresse térmico, permitindo a antecipação de falhas em cascata.

Essa separação garante que cada equipe técnica consuma a parcela dos dados pertinente à sua esfera de atuação, amparada pelas mesmas Tabelas Fato padronizadas em alta performance.

5 RESULTADOS E AVALIAÇÃO DE PERFORMANCE (ENGENHARIA)

A seção de Resultados subdivide-se em duas esferas de validação. Inicialmente, uma bateria de testes sob estresse estabelece os limites arquiteturais do motor Apache Druid, atestando a estabilidade da engenharia de *hardware* frente a gargalos induzidos. Em seguida, a pesquisa transpõe o *pipeline* estruturado para o mundo real, operando-o na simulação tática do cenário de crise climática e ambiental brasileira ao longo do ano de 2025.

5.1 Volumetria Espacial e Eficiência de Compressão

Antes de prosseguir com a análise de vazão computacional, a Tabela 2 consolida a magnitude da infraestrutura analítica do SIRDA. Embora a camada analítica (OLAP) lide com um montante superior a 4 milhões de entidades, o peso total de armazenamento nos *Historical Nodes* não ultrapassou a marca de 850 Megabytes físicos, distribuídos em 695 segmentos compactados.

Tabela 2: Volumetria de Entidades no Apache Druid.

Entidade Lógica	**Tipo**	**Registros Aprox.**	**Função no Esquema**
Fato Focos Incêndio	Fato	3.335.198	Coordenadas brutas INPE/NASA
Fato Eventos Incêndio	Fato	147.560	Polígonos DBSCAN
Hospitais (CNES)	Dimensão	550.882	Ativos de pressão humanitária
Rodovias Federais (DNIT)	Dimensão	14.255	Logística e evacuação
Subestações e Linhas (ONS)	Dimensão	2.564	Malha energética sistêmica
Municípios Brasileiros [2]	Dimensão	5.564	Malha geopolítica e demográfica
Terras Indígenas (FUNAI)	Dimensão	650	Polígonos de fronteira étnica
Total Analítico	–	**4.056.673**	**Alocados em ∼850 MB**

Essa eficiência de compactação colunar atesta na prática as escolhas arquiteturais do *Esquema Constelação* atrelado ao motor Druid. Ao delegar o peso geométrico complexo integralmente às Tabelas de Dimensão e operá-las via *Lookups* globais, a arquitetura isola o crescimento massivo das anomalias térmicas, viabilizando as métricas de baixíssima latência que serão discutidas nas baterias de testes subsequentes.

5.2 Avaliação Preliminar do Motor Analítico (Março/2026)

Um estudo preliminar (março de 2026) avaliou o desempenho bruto do Apache Druid sobre ~3,1 milhões de registros do INPE. Naquela etapa inicial do projeto, a arquitetura Silver ainda não havia sido desenvolvida. Portanto, o cenário operava exclusivamente com filtros tabulares simples sobre a tabela fato crua, sem o gargalo matemático das intersecções espaciais complexas (GeoJSON).

O experimento submeteu 6 *queries* de referência a diferentes alocações de CPU (2, 4 e 6 núcleos) em dois cenários opostos: estado bruto de ingestão (fragmentado em 6.518 *Tiny Segments*) e estado compactado (granularidade `YEAR`).

A Figura 7 sintetiza o impacto estrutural. No estado fragmentado, o sistema atingiu um teto de I/O em ~1.624ms mesmo com 6 núcleos, evidenciando a Lei de Amdahl perante o *overhead* de 6.518 *file handles*. Em contraste, a simples compactação despencou a latência média para ~55ms. Mantendo o mesmo hardware, a aceleração chegou a quase 39 vezes no cenário de 4 núcleos. Com o disco organizado, todas as consultas passaram a responder em sub-100ms utilizando apenas 2 núcleos (Figura 8).

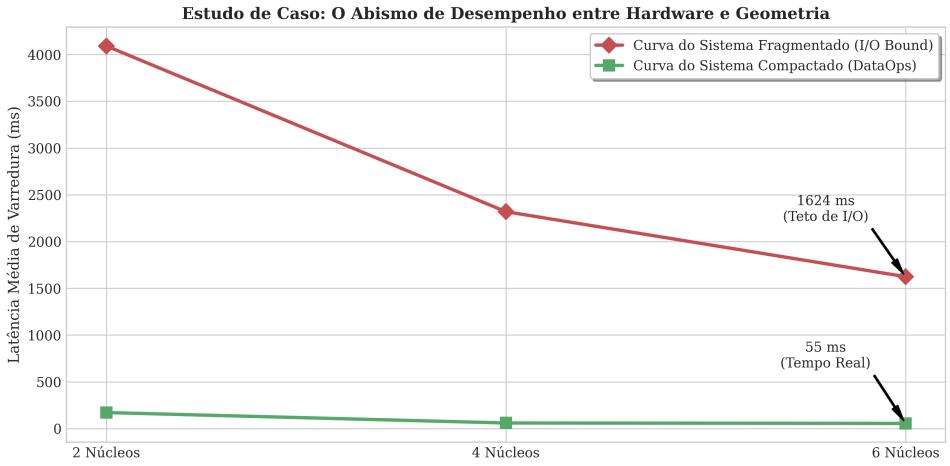


Figura 7: Comparativo de Desempenho: Dados Fragmentados vs. Compactados.

A Tabela 3 quantifica a magnitude dessa otimização. A intervenção algorítmica revelou-se sistematicamente superior à infraestrutura física: o sistema estrangulado a 2 núcleos lendo a base compactada (171ms) foi, na prática, **~9,5 vezes** mais rápido do que o hospedeiro em potência máxima (6 núcleos) tentando processar o caos estrutural (1.624ms).

Tabela 3: Redução de Latência Relativa por Alocação de CPU.

Hardware	Cold Start (Frag.)	Cold Start (Comp.)	Aceleração
2 Núcleos	4.092 ms	171 ms	23,9×
4 Núcleos	2.320 ms	60 ms	38,8×
6 Núcleos	1.624 ms	55 ms	29,4×

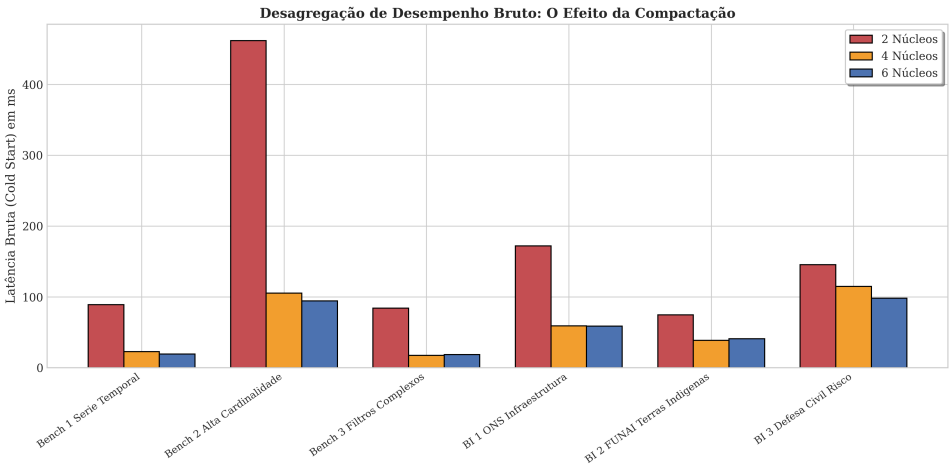


Figura 8: Latência por Domínio de Consulta após Compactação (Março/2026).

5.3 Matriz de Capacidade e Saturação (Throughput)

Embora a arquitetura básica exija escasso poder computacional (sub-100ms com 2 núcleos), a topologia *Medallion* introduz alta complexidade matemática. O carregamento estrito de volumetrias da camada *Silver* (e.g., polígonos GeoJSON de Terras Indígenas) desloca violentamente o gargalo sistêmico do I/O de disco para a CPU e Memória (*Heap* da JVM). Para validar a resiliência estrutural a esse cenário logístico severo, executou-se a matriz de capacidade concorrente.

A avaliação atestou que a renderização de mapas analíticos sob a arquitetura empregada é primariamente *CPU-Bound*. O cenário **Baseline (1.0 CPU)** apresentou degradação de desempenho logo no primeiro operador, estagnando em **0,89 QPS** com falha em 42,7% das requisições (*Timeouts*). Isso atesta que um núcleo solitário não sustenta a alta carga de alocação de memória exigida pelos *Lookups* dimensionais (que transferem as volumosas matrizes GeoJSON, previamente cruzadas na camada Silver pelo Python, para o *Heap* do Druid).

Em contrapartida, a alocação expandida no cenário **Query Heavy (2.0 CPU)** demonstrou resiliência operacional. O sistema escalou a vazão (*Throughput*) de forma constante, suportando até 16 *threads* simultâneas e formando um platô sustentável na marca de **~2,0 QPS**. Nesse estado resiliente, novas conexões aguardam em fila, mas são integralmente entregues sem geração de *Timeouts HTTP 500* (0% de erro).

Nota-se, contudo, a presença eventual de *outliers* negativos na curvatura de vazão linear. Em pontos específicos da escalada da carga, o sistema sofreu quedas abruptas de vazão em janelas milissegundares. Levanta-se a forte hipótese técnica de que este comportamento anômalo remeta a pausas prolongadas de *Garbage Collection* (GC *Stop-The-World*) e a eventos de *Thread Contention*, embora essa suposição exigisse medições com *profilers* ativos na JVM para constatação isolada.

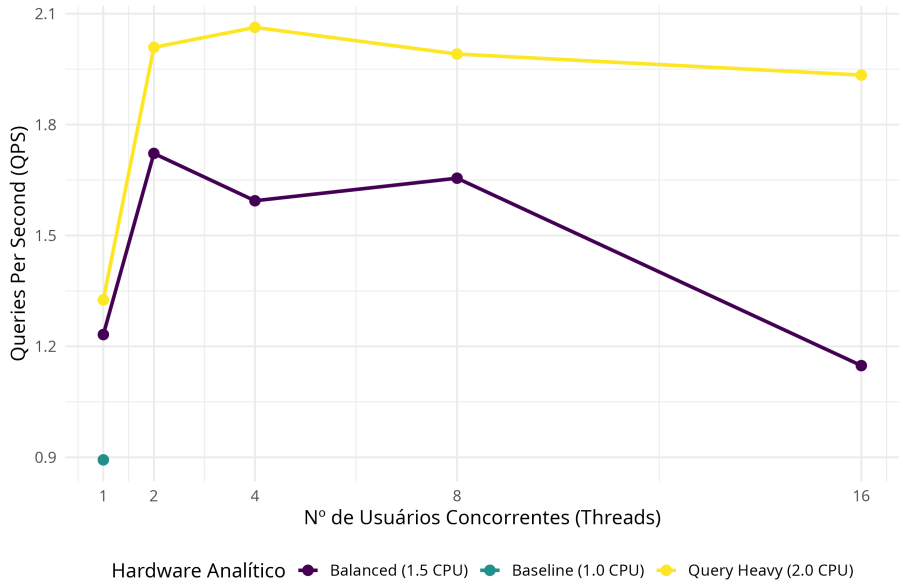


Figura 9: Vazão Analítica (QPS) por Perfil de Escalabilidade.

5.4 Explosão de Latência e Percentil 95 (P95)

Conforme demonstrado estatisticamente, no cenário *Baseline* a latência e o volume de falhas descontrolaram-se já no primeiro operador em rede. Em contraste, o cenário *Query Heavy* absorveu o impacto geométrico sem gerar interrupções, contendo a latência P95 na faixa aceitável de **~2,8 segundos** (com 2 operadores) até o limiar de **~8,2 segundos** sob o estresse de 8 operadores processando agregações massivas simultaneamente.

Contudo, fora da curva de 95% (*outliers*), registraram-se picos de latência. Esses engasgos ocorrem quando cruzamentos espaciais densos (e.g., sobreposição espacial em Terras Indígenas) esgotam a memória *Heap* da JVM e os *Merge Buffers*, forçando pausas prolongadas de *Garbage Collection* (GC). Ressalta-se que tais anomalias foram induzidas por *queries* puramente de estresse (sem amarras temporais). Na operação real do SIRDA, filtros de temporalidade (ex: janela crítica de 7 dias) impedem que um pacote GeoJSON dessa magnitude congestione a memória em uma única requisição.

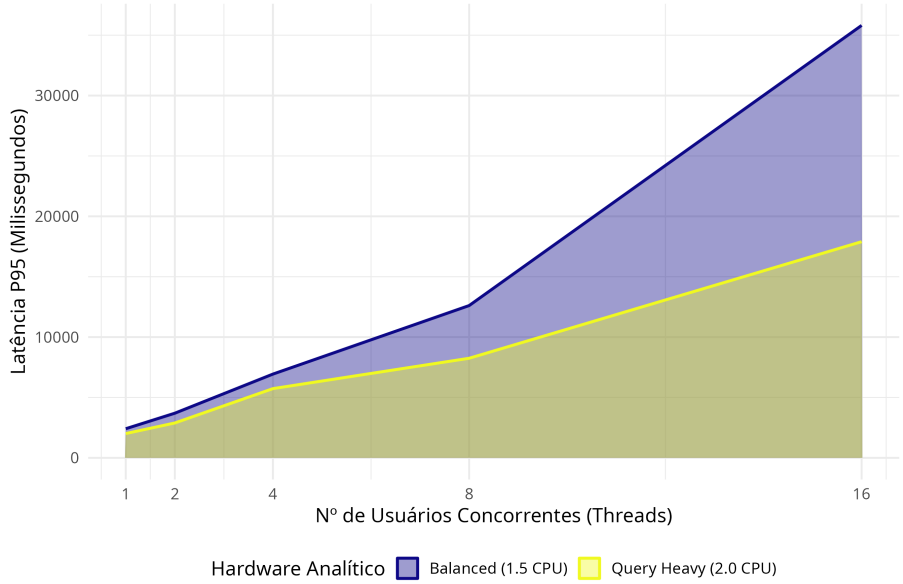


Figura 10: Degradação de Latência (P95) durante Escalonamento.

5.5 Eficiência do Mecanismo de Cache de Memória

No contexto operacional da plataforma SIRDA, painéis gerenciais (*Dashboards*) promovem uma forte redundância de consultas similares por diferentes operadores. O mecanismo nativo de intercepção (*Broker Query Cache*) provou atuar mitigando a debilidade da restrição de processamento de núcleo.

Pela ótica da escala logarítmica representada, as requisições puras ao disco e aos segmentos de dados (*Cold Start*) operam em densidades predominantemente acomodadas acima de 10^3 (1.000 a 10.000 milissegundos). Por sua vez, o acerto de memória (*Warm Start*) reduz drasticamente a latência para faixas abaixo de 10^2 (sub-100 milissegundos), garantindo que metade da atividade analítica pesada seja entregue numa magnitude de quase tempo real e economizando leituras nos índices colunares subjacentes (*Bitmap Indexes*).

A base matemática exibiu extensões esguias persistentes no violino de aquecimento (caudas longas no cenário *Warm*), atestando instantes em que requisições repetidas demoraram o mesmo ou até mais tempo que requisições originais em disco. A hipótese analítica primária para este fenômeno de *outliers* recai sobre a ocorrência de *Cache Eviction* sistêmico. Sob carga frenética e concorrente, postula-se que o vetor local de memória do *Broker* lota precocemente de dados variados, sendo forçado a "despejar"(remover) painéis outrora armazenados.

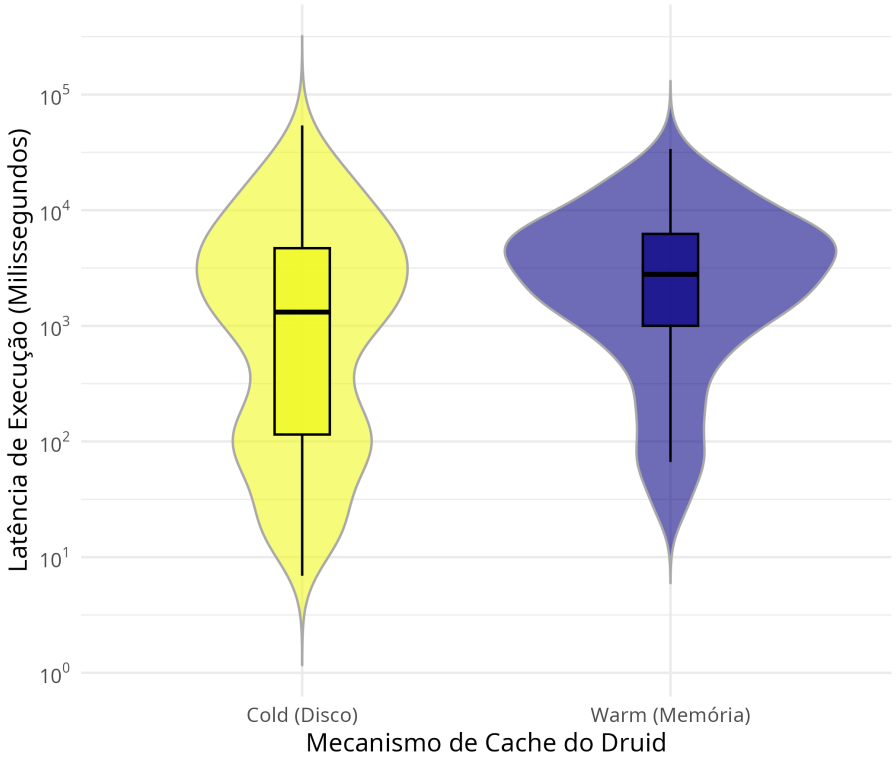


Figura 11: Distribuição de Latência: Cache vs. Leitura Nativa.

5.6 Consumo Físico de Contêineres e Esgotamento (Memory Footprint)

A série temporal corrobora a estabilidade dos nós conteinerizados perante o limite estrito do *Cgroup* (Docker), demonstrando teto rígido (inferior a 90%) e atestando a ausência de vazamento de memória (*Memory Leak*). O motor de varredura (*Historical*) acomoda-se em platôs seguros (70%-80%) durante as rajadas de carga.

De maneira análoga, o contêiner integrador (*Broker*) exibe um comportamento resiliente, evidenciando que grandes cargas cartográficas em memória (GeoJSON) são velozmente serializadas, com espaço recuperado pelas rotinas de limpeza da JVM (*Garbage Collection*). Sem o registro de falhas por esgotamento (*OOM Killed*), conclui-se que o verdadeiro gargalo analítico da plataforma reside no processamento matemático espacial (restrição de vCPU), e não na escassez de RAM.

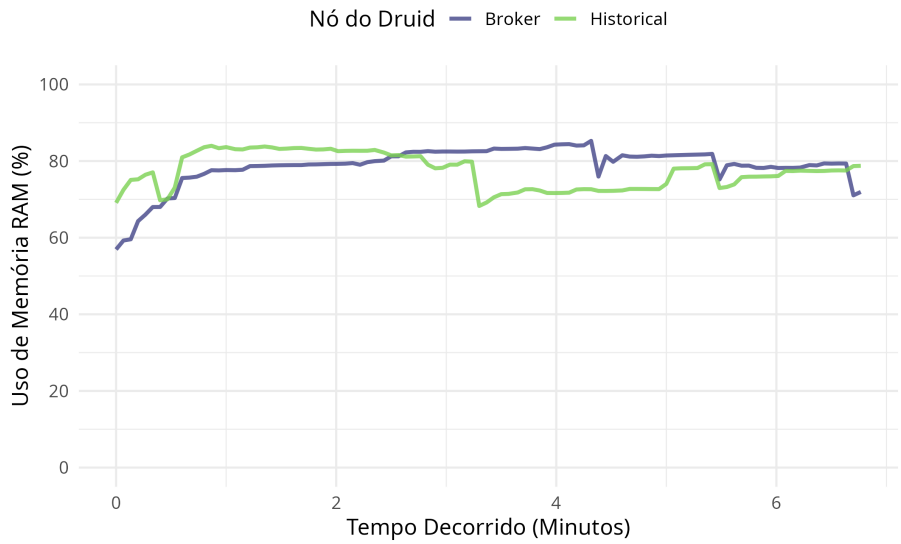


Figura 12: Oscilação do Consumo de RAM no Apache Druid.

5.7 Análise Operacional do Cenário de Crise Ambiental (2025)

Após a otimização arquitetural, a plataforma foi submetida a um cenário extremo de estiagem e incêndios florestais baseados no monitoramento de anomalias térmicas via sensoriamento remoto [10]. O sistema permitiu transformar o volume massivo de biometria de calor crua (*raw fire points*) em inteligência tática aplicável à infraestrutura nacional.

5.7.1 Panorama Geral e Dinâmica nos Biomas

A crise ambiental atingiu o território nacional de forma aguda e irregular. A Figura 13 ilustra um painel analítico focado na amostra de outubro de 2025 (pico da estiagem), evidenciando os focos ativos, a área destruída e a severidade do evento (FRP). O painel atesta a macro-evolução do desastre, marcada por um comportamento escalonado e contínuo impulsionado pelo acúmulo agudo das condições de seca.



Figura 13: Visualização Analítica de Ignições (Apache Superset).

5.7.2 Impacto em Comunidades Vulneráveis: Terras Indígenas

Uma das principais premissas táticas foi mensurar o nível de ameaça sistêmica às comunidades originárias utilizando as malhas poligonais oficiais da FUNAI. O motor analítico rastreou com precisão o cruzamento físico e a aproximação marginal (buffers) das coordenadas de fogo sobre essas demarcações. O resultado prático consolidou um ranking geoespacial de pressão social exibido na Figura 14, revelando os territórios indígenas que apresentaram alta vulnerabilidade espacial.

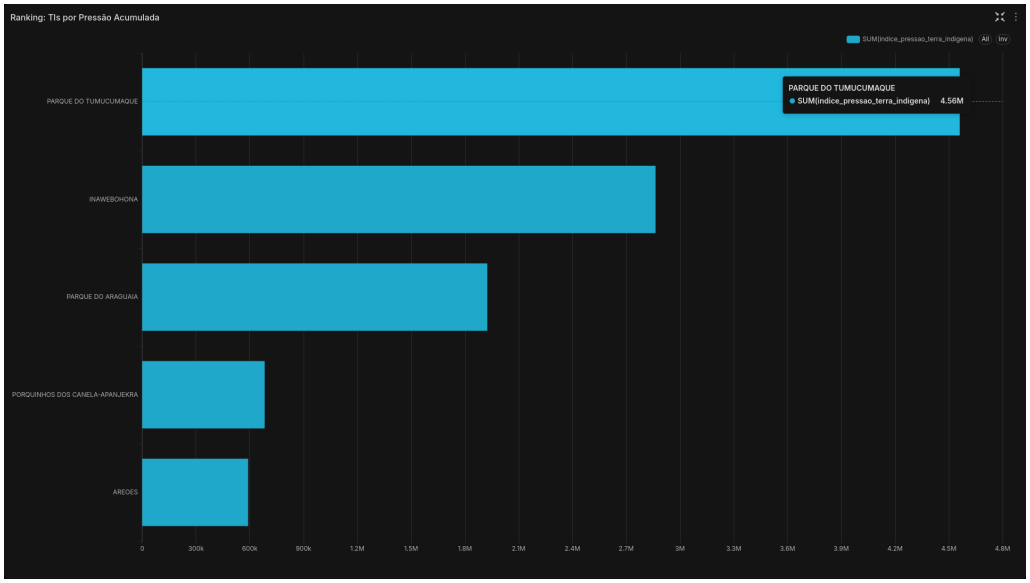


Figura 14: Volumetria de Focos em Terras Indígenas.

A agregação analítica classificou a **Terra Indígena Parque do Araguaia** (Formoso do Araguaia/TO) no 3º lugar do ranking de vulnerabilidade com base nos dados de 2025. Levanta-se a hipótese de que essa elevada concentração de anomalias térmicas reflita o avanço do pólo agroindustrial para a porção sul da Ilha do Bananal. Embora o índice calculado não determine causalidade direta para eventos isolados, as métricas parecem corroborar a narrativa cíclica de degradação na região. Segundo reportagem do portal G1, em setembro de 2026, um novo incêndio destruiu 38 residências na Aldeia Canoanã, inserida na mesma demarcação [9]. A identificação prévia deste território no topo do ranking sugere que a plataforma pode atuar como um instrumento de apoio para o mapeamento de tendências de exposição e subsidiar ações preventivas.

5.7.3 Ameaça à Infraestrutura Crítica: Setor Elétrico e Saúde (SUS)

A integração central do projeto foi materializada na intersecção veloz entre as medições dos satélites termais e a infraestrutura civil mapeada. Centros hospitalares localizados nos arredores dos epicentros rurais de incêndio sofreram o reflexo primário de densas massas regionais de fumaça, gerando alto impacto na região de cobertura das unidades de saúde. O controle exibido na Figura 15 rastreou não apenas o quantitativo, mas a intensidade da radiação (FRP) sobrepostas às coordenadas do Cadastro Nacional de Estabelecimentos de Saúde (CNES).

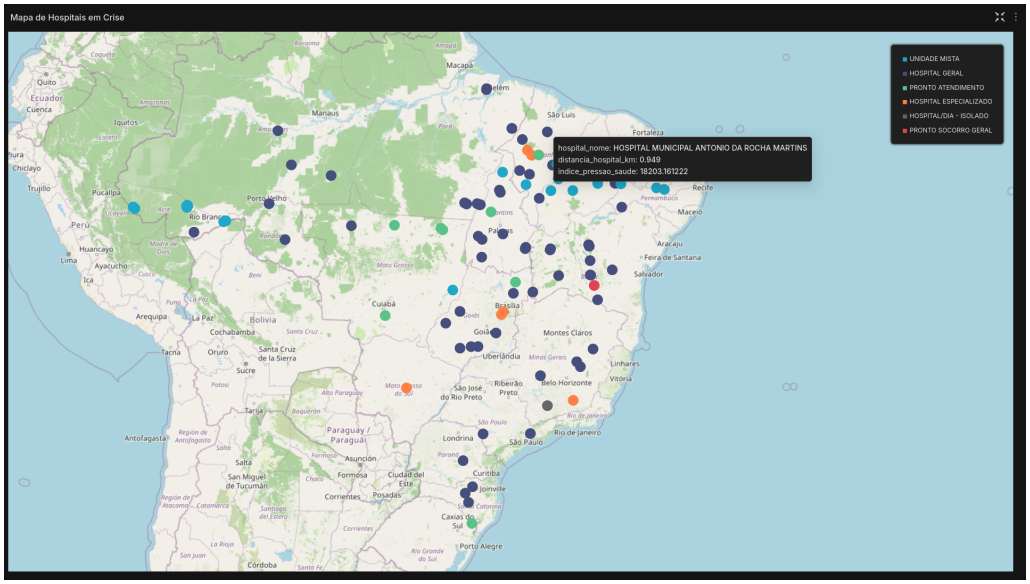


Figura 15: Monitoramento de Hospitais Expostos ao Fogo.

Da mesma forma sistêmica, os dados estenderam o cordão sanitário para resguardar a malha operada pelo Operador Nacional do Sistema Elétrico (ONS). A exposição das linhas de transmissão a focos de calor intenso gera o perigo extremo de arcos elétricos e curtos-circuitos da rede neutra para a terra (desligamento forçado).

A Figura 16 modela a progressão sistêmica dessa ameaça ao longo de todo o ano

de 2025. A série temporal atua como uma evidência analítica crucial para demonstrar a assimetria da crise: o índice permanece baixo no primeiro semestre e cresce de forma acentuada a partir de setembro e outubro nas regiões de escoamento energético. Essa métrica expõe como as condições de seca extrema submetem repentinamente a infraestrutura a um aumento de pressão crítico e de complexa mitigação logística.

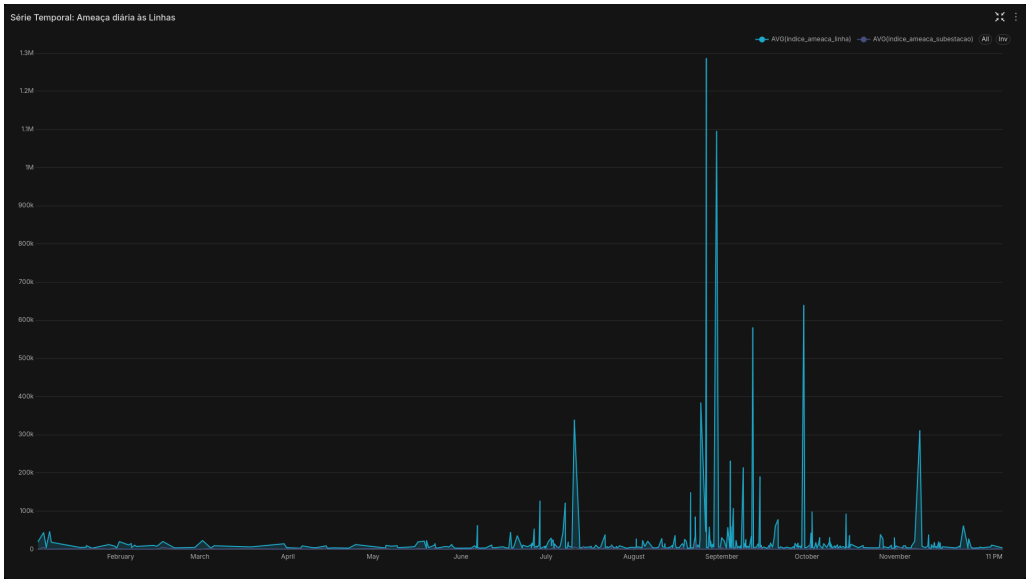


Figura 16: Evolução da Ameaça à Infraestrutura Elétrica (ONS).

Aliando o risco termal agudo com as métricas topológicas (*Betweenness Centrality*) previamente estabelecidas, a plataforma consolidou a Tabela 4. Ela enumera as subestações mais expostas a interrupções operacionais, ordenadas pelo potencial de indução de risco sistêmico em rede. O cruzamento destacou vértices infraestruturais vitais, a exemplo da SE Rio Verde Norte (GO), elo de escoamento do Norte para o Sudeste; da SE Assis (SP), coletora da bacia do Rio Paraná; e da SE Trindade (GO), pivô na interligação Norte-Sul [5, 16].

Quando nós de energia sob Risco **Extremo** sofrem desligamento forçado, a matriz energética redistribui a carga base por rotas mais longas. Esse fenômeno sobrecarrega linhas secundárias e aciona sistemas primários de proteção (como o Esquema Regional de Alívio de Carga - ERAC), culminando no risco agudo de apagões regionais e blecautes em cascata por todo o subsistema interligado do país [17].

Tabela 4: Top 10 Subestações Críticas via Betweenness Centrality.

Subestação	Capacidade (MW)	Betweenness Centrality	Risco Cascata
R.VERDE NORTE	1344.00	100.00	EXTREMO
ASSIS	2808.00	98.21	EXTREMO
TRINDADE	1600.00	91.33	EXTREMO
SAMAMBAIA	6000.00	89.30	EXTREMO
XAVANTES	600.00	89.22	EXTREMO
BANDEIRANTES	2542.00	87.68	EXTREMO
LONDRINA ESU	2016.00	59.42	ALTO
BOM.JES.LAPA II	850.00	47.07	MEDIO
LUZIANIA	450.00	46.83	MEDIO
MIRACEMA	10359.00	45.51	MEDIO

6 CONCLUSÕES

Esta pesquisa aplicou o paradigma *DataOps* para construir uma plataforma analítica de Defesa Civil, mitigando a fragmentação de bases institucionais (INPE, FUNAI, ANEEL, DATASUS, DNIT e IBGE). A análise do cenário evidenciou forte sazonalidade das anomalias térmicas a partir de setembro, impulsionada por secas prolongadas. O cruzamento espacial demonstrou que o avanço das chamas transcendeu a degradação florestal, exercendo pressão aguda sobre territórios indígenas e infraestruturas críticas civis, com destaque para a vulnerabilidade da malha de transmissão de energia frente ao calor convectivo e a exposição de hospitais às massas de fumaça.

Sob a ótica metodológica, o estudo atestou o valor da unificação entre ciência de redes e geoprocessamento. A formulação de um Índice de Pressão, atrelando a intensidade radiativa dos satélites (FRP) à vulnerabilidade civil, permitiu classificar as ameaças com maior embasamento quantitativo. Complementarmente, a aplicação da teoria dos grafos através da biblioteca *NetworkX* viabilizou a modelagem do Risco Sistêmico, fornecendo uma base lógica para identificar os vértices estruturais da rede elétrica cuja falha poderia induzir apagões em cascata.

Tecnicamente, os resultados indicam a viabilidade do ecossistema proposto, erigido integralmente sobre ferramentas de código aberto (*open-source*). A orquestração declarativa (Dagster) e os fluxos desacoplados (Apache Kafka) compuseram a infraestrutura base do sistema. No *front* analítico, testado empiricamente, o Esquema Constelação no Apache Druid demonstrou capacidade para indexar grandes volumes de anomalias térmicas, sustentando agregações de baixa latência e filtragens espaciais, mesmo sob limites estritos de processamento.

Por fim, conclui-se que o arcabouço tecnológico estruturado atua como um facili-

tador técnico para os órgãos de resposta a emergências. A pesquisa indica que a latência e o isolamento na correlação de dados geoespaciais em larga escala podem ser consideravelmente minimizados através de uma arquitetura *DataOps* integrada. Dessa forma, espera-se que o sistema contribua como uma ferramenta analítica de apoio, fornecendo insumos estruturados para embasar a tomada de decisão frente à crescente complexidade dos desastres ambientais.

AGRADECIMENTOS

Os autores agradecem ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) e à Universidade Federal de Itajubá (UNIFEI) pelo apoio acadêmico, financeiro e de infraestrutura fundamentais para a realização desta pesquisa.

Gabriel Gonçalves Sampaio
Bolsista de Iniciação Científica (IC)

Profª. Dra. Barbara Pimenta Caetano
Professora Orientadora (PQ)

Referências

[1] AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL). Sistema de informações geográficas do setor elétrico (sigel) - camadas de transmissão, 2026. Acesso em: 11 set. 2026.

[2] T. Brugz. Geodata-br, 2026. Repositório GitHub. Acesso em: 11 set. 2026.

[3] CENTRO GESTOR E OPERACIONAL DO SISTEMA DE PROTEÇÃO DA AMAZÔNIA (CENSIPAM). Painel do fogo, 2026. Acesso em: 25 set. 2026.

[4] Surajit Chaudhuri and Umeshwar Dayal. An overview of data warehousing and olap technology. *ACM SIGMOD Record*, 26(1):65–74, 1997.

[5] EMPRESA DE PESQUISA ENERGÉTICA (EPE). Plano decenal de expansão de energia 2032, 2022. Acesso em: 24 set. 2026.

[6] Mica R. Endsley. Toward a theory of situation awareness in dynamic systems. *Human Factors*, 37(1):32–64, 1995.

[7] Julian Ereth. Dataops: towards a definition. In *Proceedings of the 13th International Conference on Wirtschaftsinformatik (WI)*, pages 104–118, St. Gallen, 2018. University of St. Gallen.

[8] FUNDAÇÃO NACIONAL DOS POVOS INDÍGENAS (FUNAI). Terras indígenas: Geoprocessamento e mapas, 2026. Acesso em: 11 set. 2026.

[9] G1 Tocantins. Incêndio destrói 38 casas em aldeia indígena na ilha do bananal, 2026. Acesso em: 24 set. 2026.

[10] Louis Giglio, Wilfrid Schroeder, and Christopher O. Justice. The collection 6 modis active fire detection algorithm and science updates. *Remote Sensing of Environment*, 178:235–248, 2016.

[11] INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). Malha territorial brasileira, 2022. Acesso em: 25 set. 2026.

[12] INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS (INPE). Programa queimadas: Banco de dados de queimadas (bdqueimadas), 2026. Acesso em: 11 set. 2026.

[13] MINISTÉRIO DA SAÚDE (Brasil). DATASUS. Cadastro nacional de estabelecimentos de saúde (cnes), 2026. Acesso em: 11 set. 2026.

[14] Ana Carolina Montoro. Brasil perdeu 30 milhões de hectares por causa de queimadas em 2024; amazônia é a mais afetada, 2025. Acessado em: 22 set. 2026.

[15] Patrick O'Neil, Betty O'Neil, and Xuedong Chen. The star schema benchmark and augmented fact table indexing. In *Performance Evaluation and Benchmarking*, pages 237–252. Springer, 2009.

[16] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Mapa do sistema interligado nacional (horizonte 2026), 2026. Acesso em: 24 set. 2026.

[17] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Procedimentos de rede: Operação e critérios de confiabilidade do sin, 2026. Acesso em: 24 set. 2026.

[18] Poder360. Brasil tem 19.462 focos de incêndio no 1º semestre, alta anual de 0,96%, 2026. Acessado em: 22 set. 2026.

[19] Fangjin Yang, Eric Tschetter, Xavier Léauté, Nelson Ray, Gian Merlino, and Deep Ganguli. Druid: A real-time analytical data store. *Proceedings of the 2014 ACM SIGMOD International Conference on Management of Data*, pages 157–168, 2014.