UNIFEI

IDFLab: Desenvolvimento de uma plataforma web para geração de curvas Intensidade-Duração-Frequência com suporte a cenários climáticos futuros

---

Revisão bibliográfica e plano de trabalho enviado para análise e deliberação da banca de TCC01

Aluno:

Pedro Lucas Crisp Pinto – Engenharia da Computação

Orientação:

Barbara Pimenta Caetano - Orientadora

bpimentacaetano@unifei.edu.br

IESTI - Unifei

Marina Batalini de Macedo - Coorientadora

marinamacedo@unifei.edu.br

IRN - Unifei

13 de julho de 2026

Sumário

1 Introdução **2**

2 Motivação **3**

3 Revisão bibliográfica **4**

3.1 Precipitação Extrema e Curvas IDF 4

3.1.1 Estacionariedade e Mudanças Climáticas 4

3.2 Ciência de Dados Aplicada à Hidrologia 5

3.2.1 Aprendizado de Máquina para Tratamento de Séries Temporais 5

3.2.2 Modelagem Estatística de Extremos 5

3.3 Plataformas Web para Computação Científica 6

3.4 Visualização de Dados 6

3.5 Boas Práticas de Engenharia de Software 7

3.6 Trabalhos Relacionados 7

4 Objetivos **9**

4.1 Objetivo Geral 9

4.2 Objetivos Específicos 9

5 Desenvolvimento IDFLab **10**

5.1 Fontes de Dados 11

5.2 *Stack* Tecnológico 11

5.3 *Pipeline* de Processamento 12

5.4 Metodologia de Validação 13

6 Resultados **14**

6.1 Resultados Preliminares 14

6.2 Resultados Esperados 14

7 Cronograma de atividades do TCC02 **15**

1 Introdução

Eventos extremos de precipitação representam um grave risco para as áreas urbanas. A falta de previsão adequada desses episódios resulta em alagamentos, sobrecarga nos sistemas de drenagem e danos estruturais severos [1]. Para garantir o dimensionamento seguro de obras hidráulicas, como galerias pluviais e reservatórios, a engenharia utiliza as curvas Intensidade-Duração-Frequência (IDF). Esse instrumento relaciona estatisticamente a intensidade da chuva, sua duração e o período de retorno aceitável [2]. Ao sintetizar décadas de dados pluviométricos em uma formulação prática para o cálculo estrutural, as curvas IDF tornaram-se o padrão técnico e científico da hidrologia de projeto [3].

A geração dessas curvas exige a aquisição de dados, o tratamento de séries históricas e o ajuste de distribuições estatísticas de extremos [4]. Por essa razão, o escopo desta pesquisa aborda a ciência de dados aplicada ao tratamento de séries temporais e as práticas de engenharia de software voltadas à construção de plataformas científicas. Esse recorte reflete a natureza interdisciplinar do projeto IDFLab.

O objetivo desta revisão teórica é sintetizar o estado da arte nas frentes abordadas, estabelecendo a base conceitual para as escolhas de modelagem e arquitetura do sistema detalhadas a seguir. A seleção priorizou livros de referência e manuais técnicos da hidrologia, em conjunto com publicações recentes sobre ciência de dados e plataformas científicas web.

A organização deste documento inicia-se pela motivação do projeto, seguida da revisão teórica que sustenta as decisões de engenharia. Em seguida, os objetivos delimitam as entregas da plataforma. A metodologia detalha as fontes de dados, a arquitetura de software e o fluxo de processamento assíncrono. Por fim, o texto consolida os resultados aguardados e o cronograma técnico para o TCC02.

2 Motivação

O dimensionamento seguro de infraestruturas hidráulicas, como galerias pluviais e reservatórios de contenção, depende diretamente das chuvas de projeto definidas pelas curvas IDF. Erros nessa etapa geram impactos diretos: o subdimensionamento causa enchentes urbanas, enquanto o superdimensionamento eleva drasticamente o custo das obras [1]. Historicamente, a engenharia operou sob a premissa da estacionariedade, assumindo que o clima do passado ditaria o do futuro. Entretanto, as mudanças climáticas têm alterado a frequência e a intensidade dos eventos extremos, comprometendo essa premissa [5]. Nesse contexto, a incorporação de projeções climáticas futuras aos estudos hidrológicos passa a representar uma necessidade para o planejamento de infraestruturas de longo prazo.

Apesar dessa necessidade crescente, observou-se que as ferramentas disponíveis no contexto brasileiro não ofereciam uma solução capaz de reunir, em um único ambiente web, as etapas necessárias para a geração de curvas IDF. As alternativas existentes consistiam, em geral, em softwares *desktop* voltados exclusivamente a dados históricos ou em plataformas que disponibilizam equações previamente calculadas, sem permitir ao usuário reprocessar dados, customizar parâmetros ou incorporar novas informações às análises [6].

O lançamento da plataforma IDF-BR [7], ocorrido durante o desenvolvimento deste projeto, reforça a relevância dessa demanda ao evidenciar o interesse da comunidade hidrológica por soluções web voltadas à análise de chuvas intensas. Entretanto, enquanto plataformas dessa natureza se concentram principalmente na disponibilização de resultados previamente processados, a proposta deste trabalho é oferecer um ambiente capaz de executar todo o fluxo analítico, desde a aquisição e o tratamento dos dados até a geração de curvas IDF históricas e futuras, permitindo análises customizadas e reprodutíveis.

A viabilidade dessa proposta está fundamentada em um trabalho de pesquisa previamente desenvolvido. O núcleo computacional responsável pela extração de máximos anuais, ajuste de distribuições estatísticas e estimação dos parâmetros das curvas IDF já foi implementado e validado em Python no contexto de uma Iniciação Científica. Assim, o principal desafio deste projeto não está no desenvolvimento dos métodos hidrológicos em si, mas na sua transformação em uma ferramenta acessível ao usuário final. Ao incorporar esse núcleo analítico a uma plataforma web, a complexidade computacional passa a ser abstraída pela infraestrutura do sistema, permitindo que o usuário interaja com os dados e configure as análises por meio de uma interface visual orientada às decisões de engenharia.

3 Revisão bibliográfica

3.1 Precipitação Extrema e Curvas IDF

O dimensionamento de estruturas hidráulicas, como redes de drenagem urbana e reservatórios de contenção, baseia-se em eventos extremos de chuva, em vez de médias de precipitação [3]. Esses eventos são caracterizados por alta intensidade, curta duração e baixa frequência de ocorrência. Para transpor esses eventos severos para o cálculo prático de engenharia, a hidrologia adota o conceito de ”chuva de projeto”: um evento de precipitação teórico e estatisticamente definido que a estrutura deve ser capaz de suportar sem falhar [1]. Essa chuva é quantificada a partir de três parâmetros interdependentes: intensidade, duração e período de retorno.

O período de retorno expressa o intervalo médio, em anos, em que um evento de dada magnitude é igualado ou superado, determinando o grau de risco aceitável para a obra. O cálculo desse Risco Hidrológico avalia a probabilidade de a chuva de projeto ser superada ao menos uma vez durante a vida útil da estrutura [2]. Como exemplo prático, ao aplicar essa formulação para uma estrutura com vida útil de 25 anos dimensionada para um período de retorno de mesma duração, o risco calculado atinge 64%. Isso evidencia que a definição desses parâmetros é uma decisão de engenharia com impactos diretos na segurança e no custo da infraestrutura.

A relação matemática que conecta esses três parâmetros é a curva IDF. A formulação mais consolidada na literatura, fundamentada na teoria dos valores extremos, expressa a intensidade da chuva por meio da seguinte equação [4]:

$$i(d, T) = \frac{\alpha(T)}{(d + \theta)^{\eta}}$$

Nesta fórmula, θ e η são parâmetros adimensionais de ajuste de forma. O termo $\alpha(T)$ incorpora a dependência com o período de retorno, sendo definido por $\alpha(T) = \lambda \cdot T^{\kappa}$, onde λ e κ representam coeficientes locais extraídos dos dados observados empíricos.

A estimativa desses quatro parâmetros (θ, η, λ e κ) exige a extração de séries de máximos anuais e o subsequente ajuste de distribuições probabilísticas. Para a derivação final dos coeficientes, a linearização da equação IDF no espaço log-log permite resolver três de seus parâmetros via regressão linear [4]. O parâmetro estrutural de tempo (θ), por sua vez, é frequentemente obtido por métodos de otimização escalar, a exemplo do algoritmo de Brent, maximizando o ajuste do modelo aos dados empíricos. Essa estruturação matemática consolida a quantificação do risco hidrológico, procedimento que, historicamente, apoiou-se na premissa de que os padrões climáticos se mantêm invariáveis ao longo do tempo.

3.1.1 Estacionariedade e Mudanças Climáticas

A hidrologia clássica apoia-se na premissa da estacionariedade, assumindo que os eventos climáticos oscilam dentro de um padrão estatístico constante ao longo do tempo [3]. Contudo, alterações na dinâmica do ciclo hidrológico invalidaram esse pressuposto [5]. Consequentemente, dimensionar estruturas com longa vida útil utilizando exclusivamente registros do passado tornou-se uma abordagem insuficiente, exigindo a incorporação de projeções de modelos climáticos globais. A aplicação prática dessas projeções, no entanto, requer a mitigação de erros sistemáticos inerentes aos modelos. Essa correção é tratada na seção seguinte, junto às demais técnicas de manipulação e tratamento de dados.

3.2 Ciência de Dados Aplicada à Hidrologia

A construção de curvas IDF depende de séries de precipitação longas, consistentes e em alta resolução temporal [4] [2]. No Brasil, as principais fontes para esse fim são o Instituto Nacional de Meteorologia (INMET) e o Centro Nacional de Monitoramento e Alertas de Desastres Naturais (CEMADEN), que disponibilizam registros horários e sub-horários [8] [9]. Para a análise de cenários futuros, o Climate Change Dataset for Brazil (CLIMBra) reúne dados diários de 19 modelos climáticos entre 1980 e 2100, com cobertura nacional e estruturação em formato NetCDF [10].

Os dados brutos provenientes de modelos climáticos, contudo, contêm erros sistemáticos (vieses) que fazem com que o modelo estime precipitações consistentemente maiores ou menores do que as observadas para uma dada localidade [11]. Para corrigir esses desvios, diversos estudos propõem diferentes métodos: o Mapeamento de Quantis (QM), que alinha as distribuições estatísticas, mas apresenta limitações para extrapolamentos [12]; o *Daily Bias Correction* (DBC), que opera percentil a percentil com menor custo computacional [13]; e o *Equidistant Quantile Mapping* (EQM), desenvolvido para máximos sub-diários, que preserva o sinal de mudança climática ao longo de cada quantil [14]. A escolha entre os métodos envolve um compromisso entre simplicidade computacional e fidelidade ao sinal climático, amplamente discutido em pesquisas da área.

Além dos vieses, os dados climáticos frequentemente esbarram na limitação da escala de coleta. Registros diários, comuns nas séries históricas mais extensas e nas projeções do CLIMBra, são insuficientes para curvas IDF, que exigem análise em frações de hora. Para converter essas matrizes de 24 horas em resoluções sub-diárias, a literatura recorre a métodos de desagregação. Embora limitados regionalmente ao estado de São Paulo, os fatores empíricos da Companhia de Tecnologia de Saneamento Ambiental (CETESB) [15] são amplamente utilizados no contexto nacional como padrão prático, justificado por sua simplicidade e ampla adoção regional. Para contornar essa restrição espacial e obter resultados estatísticos mais rigorosos, o modelo estocástico de Bartlett-Lewis surge como uma alternativa avançada capaz de simular a estrutura temporal dos pulsos de chuva [16].

3.2.1 Aprendizado de Máquina para Tratamento de Séries Temporais

Apesar da vasta disponibilidade de dados meteorológicos, as séries históricas observadas frequentemente apresentam lacunas de medição. A ausência de registros contínuos quebra a integridade da temporalidade e invalida a extração estatística rigorosa dos máximos anuais. Para contornar esse problema e realizar o preenchimento dessas falhas, a literatura tem adotado abordagens baseadas em aprendizado de máquina, em substituição às técnicas tradicionais de regressão [17]. Nesse contexto, o algoritmo *Random Forest* [18] destaca-se por seu alto desempenho.

Em um estudo comparativo avaliando 19 métodos distintos para a imputação de dados meteorológicos observados, esse modelo obteve os melhores resultados simultâneos nas métricas de coeficiente de determinação (R^2), Erro Percentual Absoluto Médio Simétrico (SMAPE), Raiz do Erro Quadrático Médio (RMSE) e Erro Absoluto Médio (MAE) [19]. A superioridade do algoritmo deve-se à sua capacidade de utilizar os registros de estações vizinhas como variáveis preditoras, identificando relações espaciais não lineares complexas para estimar e preencher os valores ausentes com alta precisão matemática.

3.2.2 Modelagem Estatística de Extremos

O dimensionamento de infraestruturas seguras exige a estimativa de eventos que superam o período de registros observados, a exemplo de chuvas com períodos de retorno de 100 ou 500 anos. Para viabilizar essa extrapolação, os máximos anuais de precipitação são ajustados a modelos matemáticos contínuos de

distribuição de probabilidade.

A literatura não estabelece um modelo universal para esse ajuste. Distribuições derivadas da Teoria de Valores Extremos, como a Gumbel e a Generalizada de Valores Extremos (GEV), possuem fundamentação teórica direta para modelagem de máximos, sendo amplamente adotadas no Brasil [2]. Em situações onde o ajuste dessas distribuições se mostra insuficiente, particularmente na presença de caudas muito assimétricas, modelos como a Distribuição de Pareto Generalizada (GPD) e a Logística Generalizada (GLO) surgem como alternativas robustas, especialmente no contexto de análise regional de frequência [20].

A seleção do modelo mais adequado exige a aplicação de critérios estatísticos de aderência capazes de quantificar objetivamente a divergência entre a distribuição teórica e os dados observados. Após a estimativa dos parâmetros de cada distribuição pelo método da Máxima Verossimilhança, a minimização da Soma dos Quadrados dos Erros (SSE) entre a função densidade de probabilidade teórica e o histograma empírico destaca-se por sua interpretabilidade direta na seleção do melhor ajuste [2].

3.3 Plataformas Web para Computação Científica

Historicamente, muitas ferramentas de análise hidrológica dependem de instalação local, configurações específicas de ambiente computacional e, em diversos casos, conhecimentos de programação, o que dificulta sua adoção e integração por um público mais amplo [21].

A adoção de plataformas web para computação científica propõe uma quebra desse paradigma ao transferir o processamento para servidores remotos, permitindo que análises sejam operadas via navegador e abstraindo a complexidade computacional do usuário final. O Google Earth Engine (GEE) [22] consolida esse modelo ao disponibilizar petabytes de dados geoespaciais e capacidade de processamento em nuvem sem instalação local, sendo amplamente adotado em estudos de monitoramento ambiental e climático. Contudo, a migração dessas análises para ambientes em nuvem oculta parte da execução dos algoritmos, reduzindo a visibilidade do usuário sobre as etapas intermediárias de processamento. Como consequência, torna-se necessário garantir mecanismos de transparência e rastreabilidade dos procedimentos adotados, ao mesmo tempo em que a interface visual assume papel central na interpretação e comunicação dos resultados produzidos.

3.4 Visualização de Dados

Nesse sentido, a transição para plataformas web resolve a barreira de acesso, mas não garante, por si só, a interpretabilidade dos resultados. Conjuntos de dados hidrológicos em alta resolução temporal, somados a múltiplos cenários climáticos, geram um volume informacional dificilmente compreendido apenas por meio de tabelas estáticas. Nesse contexto, a literatura estabelece que a representação gráfica não deve ser arbitrária, mas derivada das tarefas analíticas do usuário. Segundo Munzner [23], para construir uma visualização eficaz, primeiro é necessário compreender corretamente o problema e as necessidades do usuário. Somente após essa etapa é possível escolher adequadamente os gráficos, mapas e mecanismos de interação que permitirão analisar os dados de forma eficiente.

Em análises científicas complexas, a tarefa central frequentemente vai além da observação isolada de uma variável, exigindo a comparação analítica entre diferentes estados de um mesmo fenômeno. Uma revisão sistemática recente [24] sobre visualização e tomada de decisão destaca que abordagens voltadas à comparação visual e ao reconhecimento de padrões, como séries temporais interativas, *dashboards* exploratórios e representações comparativas de cenários, favorecem a compreensão de dados complexos e a extração de insights para apoio à decisão.

No domínio hidrológico, tais estratégias mostram-se particularmente adequadas para confrontar registros históricos de eventos extremos com projeções climáticas futuras, permitindo identificar tendências, divergên-

cias e possíveis impactos de diferentes cenários de forma mais intuitiva do que por meio de tabelas ou dados brutos.

3.5 Boas Práticas de Engenharia de Software

Os requisitos de rastreabilidade, reprodutibilidade e manutenção discutidos anteriormente tornam a engenharia de software um elemento central no desenvolvimento de plataformas científicas. Além da implementação dos métodos hidrológicos e estatísticos, é necessário definir claramente os requisitos da aplicação, estruturar o armazenamento dos dados e planejar o fluxo de interação dos usuários. Essa abordagem permite transformar procedimentos tradicionalmente executados de forma manual em um processo padronizado, reduzindo erros e facilitando futuras expansões estruturais [25].

O rigor documental estabelece a base para o principal critério de validação na pesquisa: a reprodutibilidade. Como a automação em servidores remotos oculta do usuário a execução intermediária dos algoritmos, a literatura estabelece que essas aplicações devem compensar a abstração arquitetural garantindo a total transparência metodológica. Para que isso seja alcançado, recomenda-se que esse tipo de sistema registre sistematicamente os parâmetros configurados, versione as bases de dados de entrada e preserve os metadados gerados em cada execução, conforme diretrizes consolidadas para pesquisa computacional reprodutível [26]. A soma de um projeto formalmente documentado com a rastreabilidade estrita das operações assegura que o processo de análise possa ser integralmente auditado e recriado, consolidando o rigor teórico necessário para a concepção dessas ferramentas.

3.6 Trabalhos Relacionados

O estudo de trabalhos relacionados revela que as ferramentas hidrológicas atuais não centralizam, em um único ambiente dinâmico, as etapas exigidas para a modelagem climática moderna. Embora existam soluções que cubram partes desse processo, a grande maioria esbarra no mesmo paradigma arquitetural: funcionam como repositórios de dados pré-computados, e não como motores de processamento interativo em tempo real.

No cenário internacional, a plataforma web *IDF_CC Tool* (Canadá) [27] destaca-se como a principal referência. Ela avança ao aplicar correção de viés e suportar as projeções climáticas globais mais recentes, o *Coupled Model Intercomparison Project Phase 6* (CMIP6). Contudo, a ferramenta restringe-se a operar sobre um banco de dados estático, sem conexão com estações meteorológicas em tempo real ou algoritmos integrados para o tratamento de falhas. Limitações metodológicas semelhantes de estacionariedade e dependência de dados fechados também são observadas em iniciativas governamentais norte-americanas, como o *NOAA Atlas 14* [28] e a *NY Projected IDF* [29].

No contexto brasileiro, a urgência em superar o uso de sistemas defasados, como o *Plúvio 2.1* [6], um software *desktop* legado que não considera as mudanças climáticas, impulsionou uma recente corrida tecnológica. A maior evidência da criticidade e da atualidade deste problema de pesquisa foi o lançamento, no início de 2026, da plataforma web *IDF-BR* (Universidade Federal de Pelotas) [7]. Esta nova ferramenta representa um marco acadêmico de grande relevância ao consolidar, pela primeira vez em uma plataforma web de acesso público, um catálogo nacional de equações de intensidade-duração-frequência adaptadas para cenários futuros.

Apesar do inegável valor científico da *IDF-BR*, sua arquitetura expõe limitações estruturais que evidenciam lacunas no setor de engenharia. Por adotar um modelo de consulta a tabelas previamente calculadas, o sistema não realiza o processamento ativo. Consequentemente, não dispõe de aquisição automatizada via *Application Programming Interface* (API) (limitando-se a dados históricos estáticos), descarta séries com falhas extensas por não possuir módulos de tratamento, inviabiliza a customização de parâmetros por parte

do usuário e ancora-se em projeções climáticas da geração anterior (CMIP5), divergindo das diretrizes do 6º Relatório de Avaliação do *Intergovernmental Panel on Climate Change* (IPCC) [30].

A análise das ferramentas supracitadas evidencia a necessidade de uma plataforma web que atue como um motor computacional ativo e customizável, em oposição à entrega de resultados estáticos. O presente trabalho insere-se nesse contexto ao integrar, em um único ambiente, desde o tratamento de dados brutos até a projeção de cenários futuros, garantindo ao usuário o controle sobre as escolhas metodológicas.

4 Objetivos

4.1 Objetivo Geral

Desenvolver uma plataforma web modular para a análise de eventos extremos de precipitação e geração automatizada de curvas IDF, centralizando a coleta de dados, o processamento estatístico e a projeção de cenários climáticos em um ambiente acessível que dispensa o domínio de programação por parte do usuário.

4.2 Objetivos Específicos

- Projetar uma interface web interativa que permita a parametrização visual de cada etapa do fluxo analítico.
- Estruturar uma arquitetura de processamento assíncrono capaz de armazenar e manipular séries históricas de grande volume, como séries horárias com mais de 25 anos, sem comprometer a responsividade da interface.
- Desenvolver o núcleo computacional hidrológico responsável pelo tratamento de falhas, extração de máximos anuais e ajuste de distribuições estatísticas, assegurando rigor metodológico na geração das curvas IDF históricas.
- Incorporar as projeções climáticas do CLIMBra e os métodos de correção de viés ao fluxo de análise, viabilizando a geração de curvas IDF para cenários futuros.
- Implementar mecanismos de gerenciamento e exportação de projetos que garantam a rastreabilidade e a reprodutibilidade das análises realizadas.

5 Desenvolvimento IDFLab

O desenvolvimento do IDFLab foi conduzido com base em metodologias consolidadas de engenharia de software. Antes de qualquer implementação, foram realizadas as etapas de levantamento de requisitos, modelagem do banco de dados, definição da arquitetura do sistema e criação da identidade visual, garantindo que as decisões técnicas estivessem alinhadas às necessidades da plataforma desde o início.

Para a gestão do desenvolvimento, adotou-se o *framework Scrum* [31], organizado em *sprints* semanais gerenciadas por meio do Notion[1]. Cada *sprint* agrupa as atividades em *epics* temáticos, como autenticação, aquisição de dados e modelagem estatística, com histórias de usuário estimadas em *story points* pela sequência de Fibonacci, onde cada valor representa uma estimativa de esforço de desenvolvimento. Essa estrutura permite rastrear o progresso e repriorizar entregas de forma incremental ao longo de todo o ciclo de desenvolvimento.

Para orientar o leitor sobre o escopo e o fluxo da plataforma antes da descrição técnica detalhada, a Figura 1 apresenta o *wireflow* do IDFLab, que ilustra as principais telas e a navegação entre elas.

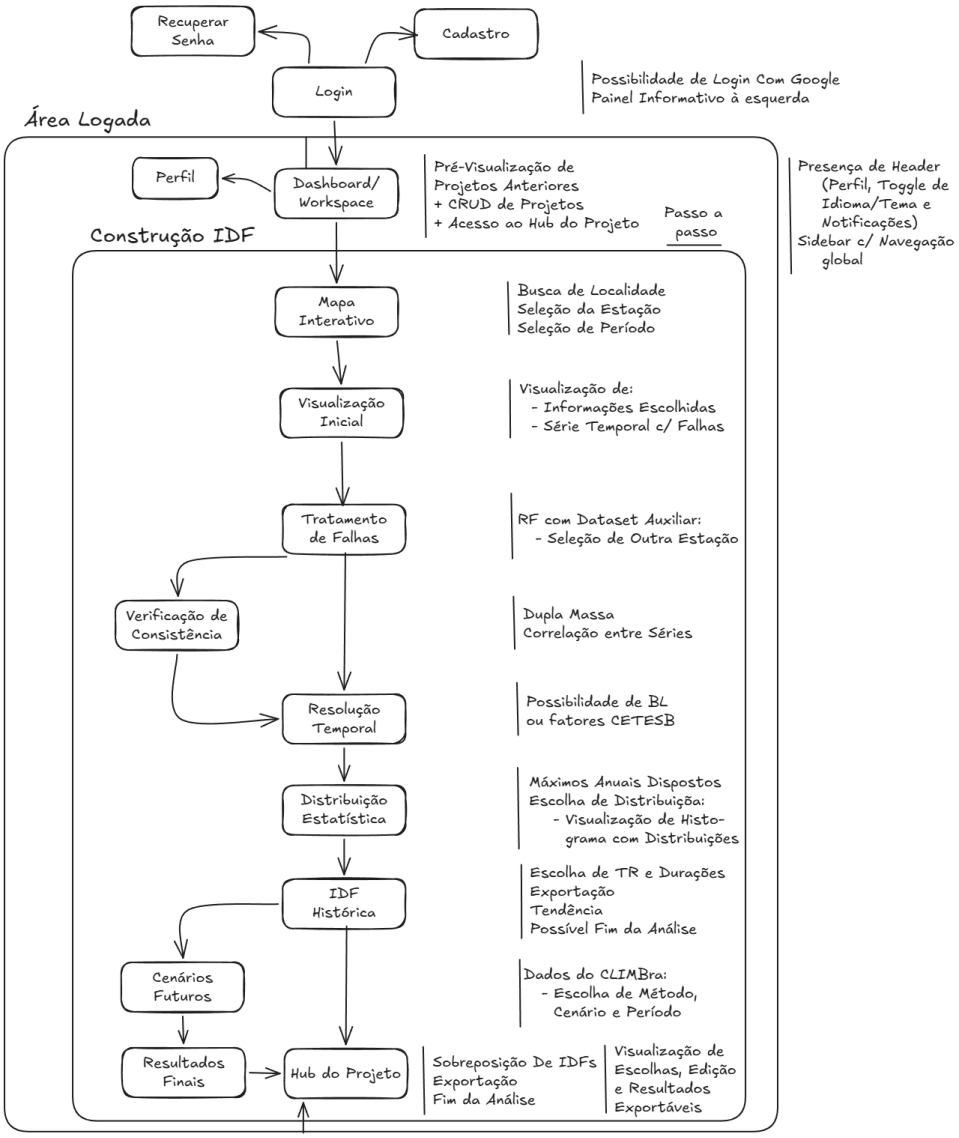


Figura 1: *Wireflow* da plataforma IDFLab.

[1]Disponível em: https://www.notion.com

As subseções seguintes detalham cada componente dessa arquitetura: as fontes de dados utilizadas, o *stack* tecnológico adotado, o *pipeline* de processamento que guia o usuário ao longo do fluxo analítico e a metodologia de validação dos resultados.

5.1 Fontes de Dados

A plataforma IDFLab utiliza três fontes de dados distintas, cada uma com um papel específico no *pipeline* de análise: INMET e CEMADEN para os dados históricos observados, e CLIMBra para as projeções climáticas futuras.

O INMET opera estações convencionais, com séries de longo prazo que remontam a 1912, e estações automáticas, que registram dados em resolução horária desde os anos 2000. Ambas disponibilizam seus acervos via API pública, permitindo que a plataforma realize a aquisição automatizada dessas séries históricas sem intervenção manual.

A rede do CEMADEN complementa a análise oferecendo resoluções mais finas, variando de 10 minutos a 1 hora, ideais para durações sub-horárias. No entanto, essas séries costumam apresentar um alto volume de falhas estruturais. Isso ocorre porque muitas de suas estações possuem transmissão acionada por eventos, ou seja, simplesmente não geram registros em períodos sem chuva. Esse comportamento técnico da rede torna a etapa de preenchimento de dados uma exigência obrigatória no sistema.

Para os cenários futuros, a plataforma integra o CLIMBra, que reúne projeções diárias de precipitação de 19 modelos climáticos globais para o período de 1980 a 2100, com cobertura nacional. Os dados são disponibilizados em formato NetCDF e podem ser lidos de forma seletiva por coordenada geográfica diretamente do repositório oficial, sem necessidade de baixar arquivos completos. Essa característica é relevante do ponto de vista computacional, pois os arquivos NetCDF do CLIMBra têm grande volume, e a leitura pontual por coordenada reduz significativamente o tempo de acesso e o consumo de armazenamento.

É importante destacar que as três fontes operam em resoluções temporais diferentes. As séries do INMET e CEMADEN são horárias ou sub-horárias, enquanto os dados do CLIMBra são diários. Essa diferença de escala tem implicação direta no *pipeline*: as projeções climáticas precisam passar por um processo de desagregação temporal antes de serem utilizadas no cálculo das curvas IDF, o que é tratado na seção 5.3.

5.2 *Stack* Tecnológico

Para suportar a ingestão, o armazenamento e o processamento do alto volume de dados provenientes das fontes descritas na seção anterior, a arquitetura da plataforma foi orientada por dois critérios principais: a compatibilidade com o ecossistema científico necessário para os cálculos hidrológicos e a capacidade de lidar com o processamento assíncrono de tarefas computacionalmente intensas.

O *backend* é desenvolvido em Python com o *framework* FastAPI[2]. A escolha do Python se fundamenta no fato de o ecossistema de computação científica relevante para este trabalho ser nativo dessa linguagem, com bibliotecas como Pandas [32] e SciPy [33]. Usar qualquer outra tecnologia no *backend* exigiria integrações externas ou reimplementações desnecessárias de algoritmos já consolidados. O FastAPI, por sua vez, é escolhido por oferecer alto desempenho na exposição de *endpoints Representational State Transfer* (REST) e suporte nativo a operações assíncronas, o que é importante dado o volume de requisições que o sistema pode receber simultaneamente.

O *frontend* é desenvolvido em Angular[3], um *framework* que favorece a organização modular do código e a

[2]Disponível em: https://fastapi.tiangolo.com/
[3]Disponível em: https://angular.io/

construção de interfaces reativas. A comunicação com o *backend* ocorre inteiramente via requisições REST, e as visualizações interativas de séries temporais, histogramas e curvas IDF são renderizadas por bibliotecas de gráficos como o Apache ECharts[4].

Para o armazenamento de dados, a plataforma utiliza PostgreSQL[5] com a extensão TimescaleDB[6]. O PostgreSQL já seria suficiente para dados relacionais comuns, como cadastro de usuários e metadados de projetos. A adição do TimescaleDB se justifica pelo perfil das séries de precipitação, que são tabelas com milhões de registros ordenados no tempo, e o TimescaleDB introduz particionamento automático por intervalo temporal e índices otimizados para esse padrão de acesso, reduzindo significativamente o tempo de consultas em janelas de tempo específicas. Dados de maior volume, como arquivos de projeções climáticas e resultados intermediários de análise, são armazenados no Cloudflare R2[7], um serviço de armazenamento de objetos que não cobra taxas de transferência de saída, o que é relevante dado o volume de dados que podem ser acessados repetidamente durante as análises.

O maior desafio operacional da plataforma é o tempo de processamento. Etapas como o preenchimento de falhas por *Random Forest* [18], a desagregação temporal e o ajuste de distribuições estatísticas podem levar vários minutos para serem concluídas. Executar essas tarefas diretamente na requisição *Hypertext Transfer Protocol* (HTTP) bloquearia o servidor e tornaria a interface inutilizável durante o processamento. Para contornar isso, a plataforma utiliza Celery[8] com Redis[9] como *broker* de mensagens: quando o usuário dispara uma análise, a tarefa é enfileirada no Redis e executada por um *worker* Celery em segundo plano, enquanto a interface permanece responsiva e atualiza o usuário sobre o progresso via notificações.

5.3 *Pipeline* de Processamento

Apoiado na arquitetura assíncrona estabelecida, o *pipeline* de processamento da plataforma é executado por meio de etapas sequenciais, onde a saída de cada rotina computacional alimenta a próxima. O usuário interage com o sistema ao longo de todo o processo, configurando parâmetros e tomando decisões a cada etapa.

O *pipeline* se inicia com a seleção da estação e do período de análise no mapa interativo, onde o usuário busca e escolhe uma estação do INMET ou CEMADEN e define o intervalo temporal de interesse. A partir dessa seleção, o sistema dispara uma tarefa assíncrona que acessa a API correspondente e armazena a série temporal bruta no banco de dados. Concluída a aquisição, o usuário tem acesso a uma visualização inicial da série, com destaque para os máximos e para as janelas de falha, permitindo uma avaliação preliminar dos dados antes de qualquer processamento.

A etapa seguinte é o tratamento de qualidade dos dados. Para o preenchimento de falhas, o usuário seleciona uma estação vizinha no mapa interativo. Antes de executar o preenchimento, o sistema calcula a curva de dupla massa e o coeficiente de correlação de Pearson entre as duas séries, permitindo que o usuário avalie a consistência e a similaridade entre elas antes de prosseguir. O preenchimento é feito por um modelo *Random Forest* treinado com os registros válidos da série principal, usando como variáveis preditoras a precipitação da estação vizinha e as componentes temporais de cada registro (ano, mês, dia e hora). O modelo é aplicado apenas aos instantes em que a série principal possui falha e a estação vizinha possui registro válido.

Com a série contínua e consistente, o *pipeline* avança para a resolução temporal. Caso os dados estejam em escala diária, o usuário escolhe entre dois métodos de desagregação: os fatores empíricos da CETESB,

[4]Disponível em: https://echarts.apache.org/
[5]Disponível em: https://www.postgresql.org/
[6]Disponível em: https://www.timescale.com/
[7]Disponível em: https://www.cloudflare.com/pt-br/developer-platform/r2/
[8]Disponível em: https://docs.celeryq.dev/
[9]Disponível em: https://redis.io/

mais simples e de aplicação direta, ou o modelo estocástico de Bartlett-Lewis, mais robusto para contextos fora do estado de São Paulo.

A etapa seguinte é a geração das curvas IDF históricas. O sistema extrai os máximos anuais para cada duração de interesse, ajusta as distribuições estatísticas disponíveis (Gumbel, GEV, Pareto e GLO) e seleciona automaticamente a de melhor aderência pelo critério SSE. A partir daí, estima os quatro parâmetros da equação IDF por regressão linear no espaço log-log, com o parâmetro θ determinado por otimização escalar limitada que maximiza o R^2 global do ajuste. O usuário define os períodos de retorno e as durações de interesse, e pode exportar os resultados ou encerrar a análise nesse ponto.

Para quem opta por incorporar cenários futuros, o *pipeline* segue para a integração com o CLIMBra. O usuário seleciona o método de correção de viés (QM, DBC ou EQM), o cenário SSP e o período de projeção. O sistema aplica a correção e gera as curvas IDF futuras, que são apresentadas sobrepostas às históricas para comparação direta. Todos os resultados ficam consolidados no *hub* do projeto, de onde podem ser exportados em *Comma-Separated Values* (CSV) ou *Portable Document Format* (PDF).

5.4 Metodologia de Validação

Para atestar a confiabilidade matemática e estatística da plataforma, a validação dos resultados será conduzida em dois eixos metodológicos: a reconstrução das séries temporais e a precisão das curvas geradas.

No primeiro eixo, o módulo de imputação de falhas (*Random Forest*) será avaliado via mascaramento de dados. Uma série histórica completa (sem falhas) terá um percentual de seus registros artificialmente ocultado. Em seguida, o algoritmo realizará o preenchimento dessas lacunas utilizando dados de estações vizinhas. Os valores sintéticos gerados pela máquina serão comparados aos dados originais ocultados, quantificando a precisão do modelo por meio de métricas de desempenho como o RMSE e o MAE.

No segundo eixo, o motor de cálculo das curvas IDF passará por uma validação cruzada contra referências consolidadas. As curvas geradas automaticamente pela plataforma serão comparadas a equações de referência previamente validadas pela equipe de orientação do projeto, com testes focados nas estações dos municípios de São Carlos e São Paulo. Como camada complementar de verificação, os resultados do sistema serão confrontados com as equações disponibilizadas pelo recente catálogo nacional da plataforma IDF-BR. Essa estratégia garante que o fluxo computacional desenvolvido não apenas reproduza fielmente os cálculos tradicionais, mas também esteja alinhado às metodologias contemporâneas da hidrologia climática.

6 Resultados

6.1 Resultados Preliminares

Na etapa inicial deste projeto, foram concluídas com êxito a especificação da arquitetura da plataforma, a estruturação de sua infraestrutura básica, o módulo de autenticação de usuários e o mapa interativo para seleção de estações pluviométricas. Adicionalmente, o núcleo computacional responsável pelas análises hidrológicas e pelo motor de geração das curvas IDF já se encontra desenvolvido, sendo decorrente de trabalhos prévios de iniciação científica. Esses marcos consolidados fornecem uma base estável para o andamento do sistema.

6.2 Resultados Esperados

Como resultado deste trabalho, espera-se disponibilizar a plataforma IDFLab em pleno funcionamento, integrando em um único ambiente acessível via navegador as etapas de aquisição de dados pluviométricos, tratamento de falhas, geração de curvas IDF históricas e projeção de cenários climáticos futuros, conforme o *pipeline* descrito na seção 5.3.

No âmbito hidrológico, espera-se obter as curvas IDF históricas das estações selecionadas para validação (São Carlos e São Paulo), ajustadas a partir das distribuições de extremos contempladas pela plataforma (Gumbel, GEV, Pareto Generalizada e GLO). A qualidade do módulo de preenchimento de falhas será quantificada pelas métricas RMSE e MAE, obtidas a partir do procedimento de mascaramento descrito na seção 5.4. Da mesma forma, espera-se reportar o grau de aderência entre as curvas geradas pela plataforma e as equações de referência da equipe de orientação, bem como frente às equações do catálogo IDF-BR, estabelecendo um indicador comparativo de acurácia do motor de cálculo desenvolvido.

Para os cenários futuros, espera-se obter curvas IDF projetadas a partir dos dados do CLIMBra após a aplicação dos métodos de correção de viés (QM, DBC e EQM), permitindo comparar diretamente os parâmetros das curvas históricas e futuras para os cenários SSP avaliados. Por fim, espera-se disponibilizar, para cada análise realizada, relatórios técnicos exportáveis em PDF e tabelas de parâmetros em formato CSV, além do registro do histórico de projetos do usuário, permitindo a rastreabilidade dos experimentos realizados e a recuperação de análises anteriores sem necessidade de reprocessamento.

7 Cronograma de atividades do TCC02

F.0: Estrutura Base da Plataforma (Resultado Preliminar)
Implementação da infraestrutura da aplicação, autenticação de usuários e desenvolvimento do mapa interativo para seleção de estações pluviométricas.
Resultados da fase 0
Base tecnológica da plataforma operacional e pronta para integração dos módulos analíticos.
F.1: Aquisição e Pré-processamento de Dados
Integração do sistema com as bases de dados meteorológicas e incorporação dos módulos de tratamento das séries temporais ao ambiente web.
Atividades planejadas para a fase 1
A.1.1 Aquisição automatizada de dados pluviométricos (APIs INMET e CEMADEN) A.1.2 Visualização exploratória das séries temporais (histogramas, máximos anuais e identificação de falhas) A.1.3 Tratamento de falhas e consistência dos dados (Dupla Massa, Correlação de Pearson e *Random Forest*) A.1.4 Adequação da resolução temporal (Fatores CETESB e Bartlett-Lewis)
Resultados esperados para a fase 1
Fluxo completo de obtenção e preparação dos dados disponível na plataforma.
F.2: Modelagem Estatística e Curvas IDF Históricas
Integração do núcleo hidrológico previamente desenvolvido à interface web e disponibilização dos resultados ao usuário.
Atividades planejadas para a fase 2
A.2.1 Ajuste estatístico dos eventos extremos (Gumbel, GEV, Pareto Generalizada e GLO) A.2.2 Geração das curvas IDF históricas (Teoria de Valores Extremos e regressão dos parâmetros da equação IDF) A.2.3 Desenvolvimento das visualizações dos resultados e parâmetros ajustados
Resultados esperados para a fase 2
Geração de curvas IDF históricas diretamente pela plataforma.
F.3: Cenários Climáticos Futuros e Exportação
Incorporação das projeções climáticas e dos métodos de correção de viés ao fluxo de análise.
Atividades planejadas para a fase 3
A.3.1 Incorporação das projeções climáticas (CLIMBra) A.3.2 Correção de viés das projeções (QM, DBC e EQM) A.3.3 Geração e comparação de curvas IDF futuras (cenários SSP)
Resultados esperados para a fase 3
Comparação entre cenários históricos e futuros disponível na plataforma.
F.4: Gerenciamento de Projetos e Funcionalidades Complementares
Implementação dos mecanismos de persistência, organização e exportação das análises.
Atividades planejadas para a fase 4

A.4.1 Desenvolvimento do ambiente de gerenciamento de projetos (*hub* de projetos e histórico de análises)
A.4.2 Implementação do sistema de acompanhamento de processamento (tarefas assíncronas e notificações)
A.4.3 Exportação de resultados (CSV e PDF)

Resultados esperados para a fase 4

Recuperação de análises anteriores e geração de relatórios.

F.5: Validação, Documentação e *Deploy*

Avaliação da qualidade dos resultados produzidos e disponibilização da plataforma em ambiente de produção.

Atividades planejadas para a fase 5

A.5.1 Avaliação do preenchimento de falhas (RMSE e MAE)
A.5.2 Comparação das curvas geradas com referências consolidadas (equações de referência e IDF-BR)
A.5.3 Publicação da plataforma em ambiente de produção (*deploy* da aplicação)

Resultados esperados para a fase 5

Plataforma validada e acessível para utilização.

F.6: Redação do TCC02 e Preparação para a Defesa

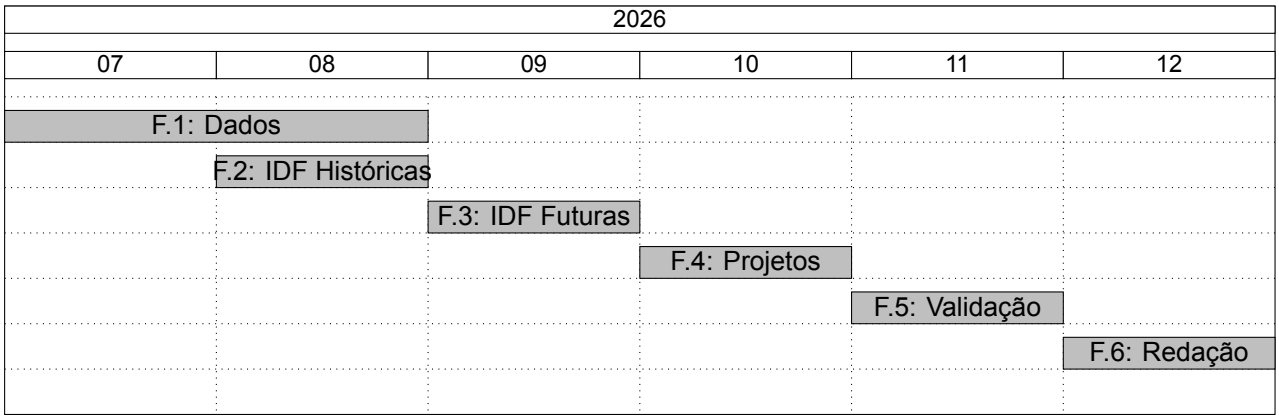
Consolidação da documentação científica e preparação da defesa.

Atividades planejadas para a fase 6

A.6.1 Consolidação da metodologia e arquitetura da plataforma
A.6.2 Redação dos resultados, discussão e conclusão
A.6.3 Preparação da apresentação e defesa do trabalho

Resultados esperados para a fase 6

Monografia finalizada e pronta para defesa.



Referências Bibliográficas

[1] C. E. M. Tucci, Ed., *Hidrologia: ciência e aplicação*, 4th ed. Porto Alegre: ABRH; Ed. UFRGS, 2012.

[2] M. Naghettini and □. J. d. A. Pinto, *Hidrologia estatística*. CPRM, 2007.

[3] V. T. Chow, D. R. Maidment, and L. W. Mays, *Applied hydrology*. New York: McGraw-Hill, 1988.

[4] D. Koutsoyiannis, D. Kozonis, and A. Manetas, “A mathematical framework for studying rainfall intensity-duration-frequency relationships,” *Journal of hydrology*, vol. 206, no. 1-2, pp. 118–135, 1998.

[5] P. C. D. Milly *et al.*, “Stationarity is dead: Whither water management?” *Science*, vol. 319, no. 5863, pp. 573–574, 2008.

[6] F. A. Pinto, P. A. Ferreira, and F. F. Pruski, *Plúvio 2.1: software para a determinação de equações de chuvas intensas*, Universidade Federal de Viçosa (UFV), Viçosa, MG, 2001.

[7] A. A. Rodrigues, T. L. C. Beskow, T. M. Siqueira, S. Beskow *et al.*, *IDF-BR: Equações para o clima atual e projeções do clima futuro – Manual Técnico e do Usuário*, Universidade Federal de Pelotas (UFPel), Pelotas, RS, 2026. [Online]. Available: https://www.idf-br.com.br/

[8] INSTITUTO NACIONAL DE METEOROLOGIA, “Banco de dados meteorológicos do inmet (bdmep),” Brasília, DF, 2026. [Online]. Available: https://portal.inmet.gov.br/

[9] CENTRO NACIONAL DE MONITORAMENTO E ALERTAS DE DESASTRES NATURAIS, “Plataforma de dados da rede de monitoramento do cemaden,” São José dos Campos, SP, 2026. [Online]. Available: https://www.gov.br/cemaden/pt-br

[10] A. S. Ballarin, J. S. Sone, G. C. Gesualdo *et al.*, “Climbra – climate change dataset for brazil,” 2024, v. 5. Science Data Bank. [Online]. Available: https://doi.org/10.57760/sciencedb.02316

[11] C. Teutschbein and J. Seibert, “Bias correction of regional climate model simulations for hydrological climate-change impact studies: Review and evaluation of different methods,” *Journal of Hydrology*, vol. 456-457, pp. 12–29, 2012.

[12] A. J. Cannon, S. R. Sobie, and T. Q. Murdock, “Bias correction of gcm precipitation by quantile mapping: how well do methods preserve changes in quantiles and extremes?” *Journal of Climate*, vol. 28, no. 17, pp. 6938–6959, 2015.

[13] F. S. Mpelasoka and F. H. S. Chiew, “Influence of rainfall scenario construction methods on runoff projections,” *Journal of Hydrometeorology*, vol. 10, no. 5, pp. 1168–1183, 2009.

[14] P. K. Srivastava *et al.*, “Sensitivity and uncertainty analysis of mesoscale model downscaled hydrometeorological variables for discharge prediction,” *Hydrological Processes*, vol. 28, no. 15, pp. 4419–4432, 2014.

[15] Companhia de Tecnologia de Saneamento Ambiental (CETESB), “Drenagem urbana: manual de projeto,” CETESB, São Paulo, SP, Tech. Rep., 1979.

[16] I. Rodriguez-Iturbe, D. R. Cox, and V. Isham, “Some models for rainfall based on stochastic point processes,” *Proceedings of the Royal Society of London. Series A*, vol. 410, pp. 269–288, 1987.

[17] A. Zamora-Maciá *et al.*, “Missing data imputation of climate time series: A review,” *PeerJ Computer Science*, 2024.

[18] L. Breiman, “Random forests,” *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.

[19] C. Li, X. Ren, and G. Zhao, “Machine-learning-based imputation method for filling missing values in ground meteorological observation data,” *Algorithms*, vol. 16, no. 9, p. 422, 2023.

[20] J. R. M. Hosking and J. R. Wallis, “Some statistics useful in regional frequency analysis,” *Water resources research*, vol. 29, no. 2, pp. 271–281, 1993.

[21] C. Erazo Ramirez, Y. Sermet, F. Molkenthin, and I. Demir, “HydroLang: An open-source web-based programming framework for hydrological sciences,” *Environmental Modelling & Software*, vol. 157, p. 105525, 2022.

[22] N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau, and R. Moore, “Google earth engine: Planetary-scale geospatial analysis for everyone,” *Remote sensing of Environment*, vol. 202, pp. 18–27, 2017.

[23] T. Munzner, “A nested model for visualization design and validation,” *IEEE Transactions on Visualization and Computer Graphics*, vol. 15, no. 6, pp. 921–928, 2009.

[24] G. Neri, S. Marshall, H. K.-H. Chan, A. Yaghi, D. Tabor, R. Sinha, and S. Mazumdar, “Data visualization in AI-assisted decision-making: a systematic review,” *Frontiers in Communication*, vol. 10, p. 1605655, 2025.

[25] I. Sommerville, *Software Engineering*, 10th ed. Boston: Pearson, 2016.

[26] G. K. Sandve, A. Nekrutenko, J. Taylor, and E. Hovig, “Ten simple rules for reproducible computational research,” *PLoS Computational Biology*, vol. 9, no. 10, p. e1003285, 2013.

[27] S. P. Simonovic, A. Schardong, D. Sandink, and R. Srivastav, “Computerized tool for the development of intensity-duration-frequency curves under climate change (idf_cc tool),” London, ON, Canada, 2023. [Online]. Available: https://www.idf-cc-uwo.ca/

[28] NATIONAL OCEANIC AND ATMOSPHERIC ADMINISTRATION, “Noaa atlas 14: Precipitation-frequency atlas of the united states,” Silver Spring, MD, 2014. [Online]. Available: https://hdsc.nws.noaa.gov/hdsc/pfds/

[29] CORNELL UNIVERSITY, “Projected intensity-duration-frequency (idf) curves for new york state,” Ithaca, NY, 2026. [Online]. Available: http://precip.eas.cornell.edu/

[30] IPCC, *Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*, V. Masson-Delmotte, P. Zhai, A. Pirani, S. L. Connors, C. Péan, S. Berger, N. Caud, Y. Chen, L. Goldfarb, M. I. Gomis *et al.*, Eds. Cambridge, United Kingdom: Cambridge University Press, 2021.

[31] K. Schwaber and J. Sutherland, “The scrum guide: The definitive guide to scrum: The rules of the game,” https://scrumguides.org/, 2020, accessed: 2026.

[32] W. McKinney, “Data structures for statistical computing in python,” in *Proceedings of the 9th Python in Science Conference*, S. van der Walt and J. Millman, Eds., 2010, pp. 56–61.

[33] P. Virtanen, R. Gommers, T. E. Oliphant *et al.*, “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020.